Día_1

```
library(matrixStats)
library(tidyverse)
library(dplyr)
library(tidyr)
library(purrr)
library(tibble)
library(ggplot2)
library(jsonlite)
library(nycflights13)
```

Introduccion inferencia estadistica

```
# Data
media = 3
varianza = 2

x <- seq(media-4*sqrt(varianza),media+4*sqrt(varianza),0.01)
y <- dnorm(x,mean=media,sd=sqrt(varianza))
plot(x,y,type="l",ylim = c(0,2))

#media es centrado y consistente.

A <- matrix(rnorm(10000*10,mean=media,sd=sqrt(varianza)),nrow=10000)
medias_n10 <- rowMeans(A)
lines(density(medias_n10),col="red")

B <- matrix(rnorm(10000*20,mean=media,sd=sqrt(varianza)),nrow=10000)
medias_n20 <- rowMeans(B)
lines(density(medias_n20),col="blue")
abline(v=media) #se ve que estan centrados
```

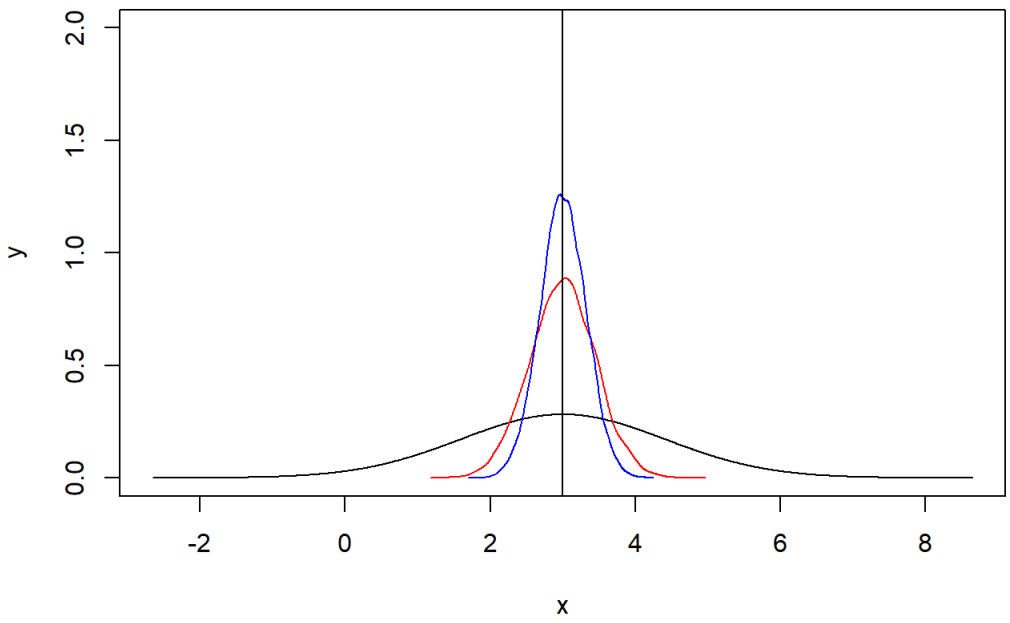


```
#que pasa con la varianza??
library(matrixStats)
vars_n10 <- rowVars(A)
plot(density(vars_n10),col="red",ylim=c(0,2))
mean(vars_n10)
```

```
## [1] 2.006982
```

```
vars_n20 <- rowVars(B)
lines(density(vars_n20),col="blue")
mean(vars_n20)
```

```
## [1] 1.998521
```

```
D <- matrix(rnorm(10000*100,mean=media,sd=sqrt(varianza)),nrow=10000)
vars_n100 <- rowVars(D)
lines(density(vars_n100),col="green")
abline(v=varianza) #se ve que estan centrados
```

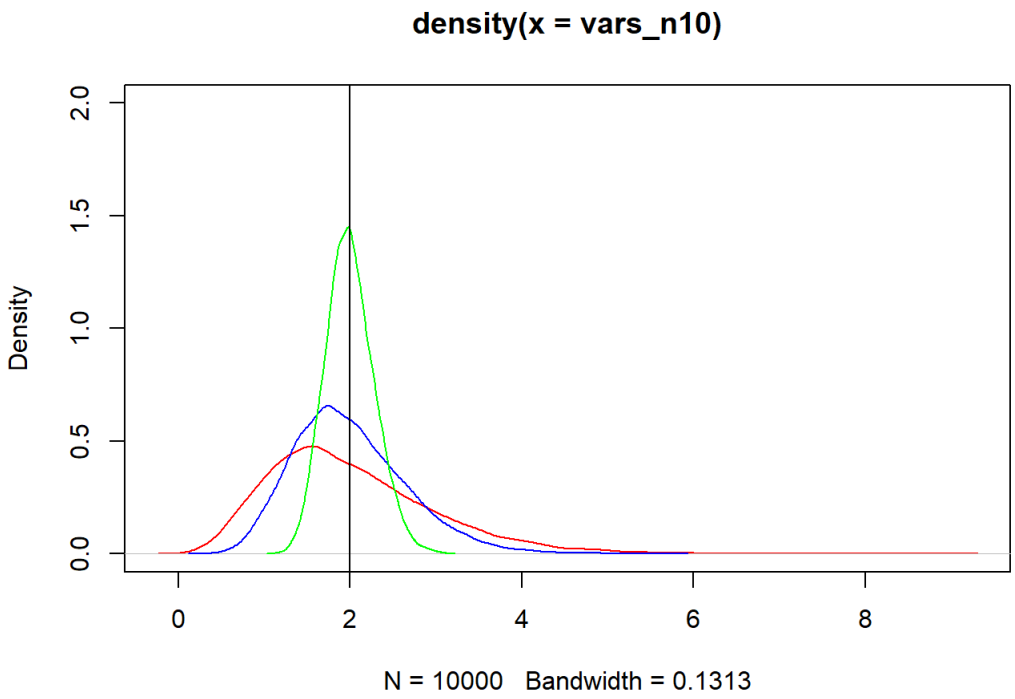


```
mean(vars_n100)
```

```
## [1] 2.001921
```

```r
####taks: codigo para mostrar que el estimador sesgado de la varianza
# es asintoticamente consitente

# 1. Crear una función que calcule la varianza con sesgo
varianza_sesgo <- function(x) {
  n <- length(x)
  media_muestra <- mean(x)
  suma_cuadrados <- sum((x - media_muestra)^2)
  return(suma_cuadrados / n)  # División por n (con sesgo), no por n-1
}

# 2. Crear una matriz E que simule tener experimentos con 1000 observaciones
E <- matrix(rnorm(10000*1000, mean=media, sd=sqrt(varianza)), nrow=10000)

# 3. Utilizar la función apply para aplicar la función a todas las filas
vars_sesgo_n10 <- apply(A, 1, varianza_sesgo)
vars_sesgo_n20 <- apply(B, 1, varianza_sesgo)
vars_sesgo_n100 <- apply(D, 1, varianza_sesgo)
vars_sesgo_n1000 <- apply(E, 1, varianza_sesgo)

# 4. Dibujar las funciones de densidad
plot(density(vars_sesgo_n10), col="red", main="Varianza con sesgo por tamaño muestral",
     xlab="Varianza", ylab="Densidad", xlim=c(1,3), ylim=c(0,4))
lines(density(vars_sesgo_n20), col="blue")
lines(density(vars_sesgo_n100), col="green")
lines(density(vars_sesgo_n1000), col="purple")
abline(v=varianza, lty=2, lwd=2) # Línea vertical en el valor real de varianza
```

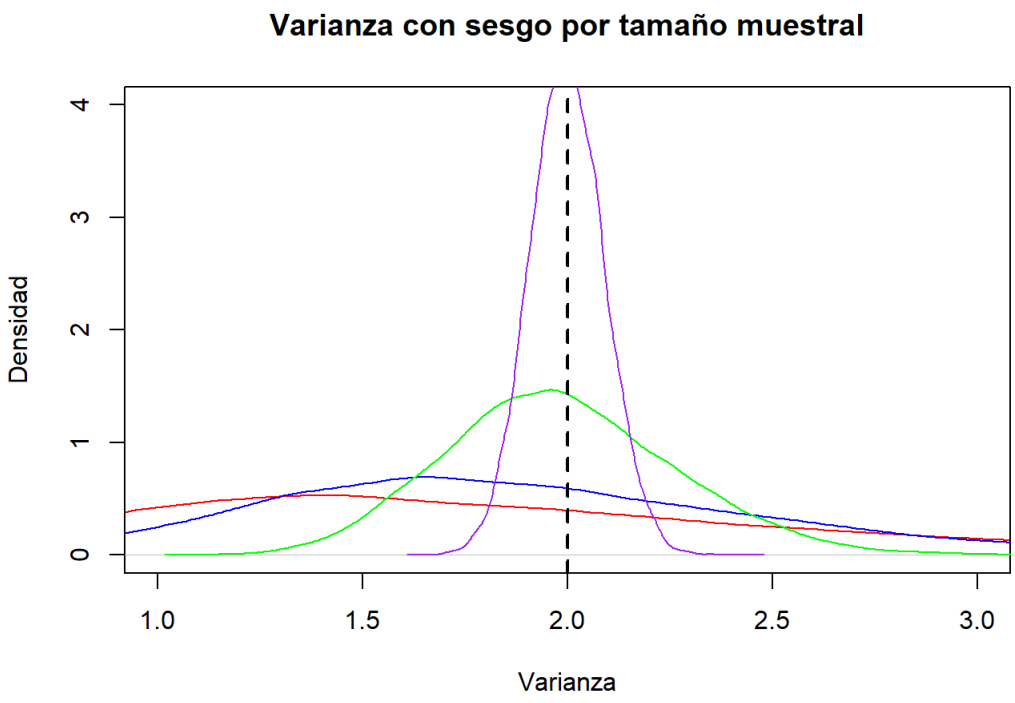


```r
# 5. Calcular la media para cada caso y observar convergencia
cat("Medias de las varianzas con sesgo:\n")
```

```
## Medias de las varianzas con sesgo:
```

```r
cat("n=10:   ", round(mean(vars_sesgo_n10), 4), "\n")
```

```
## n=10:    1.8063
```

```r
cat("n=20:   ", round(mean(vars_sesgo_n20), 4), "\n")
```

```
## n=20:    1.8986
```

```r
cat("n=100:  ", round(mean(vars_sesgo_n100), 4), "\n")
```

```
## n=100:   1.9819
```

```r
cat("n=1000: ", round(mean(vars_sesgo_n1000), 4), "\n")
```

```
## n=1000:  1.999
```

```r
cat("Varianza real: ", varianza, "\n")
```

```
## Varianza real:  2
```

```r
# Comparación con varianza sin sesgo (la que ya tenías)
cat("\nComparación con varianza sin sesgo:\n")
```

```
##
## Comparación con varianza sin sesgo:
```

```r
cat("Con sesgo n=10:    ", round(mean(vars_sesgo_n10), 4), "\n")
```

```
## Con sesgo n=10:     1.8063
```

```r
cat("Sin sesgo n=10:    ", round(mean(vars_n10), 4), "\n")
```

```
## Sin sesgo n=10:     2.007
```

```r
cat("Con sesgo n=100:   ", round(mean(vars_sesgo_n100), 4), "\n")
```

```
## Con sesgo n=100:    1.9819
```

```r
cat("Sin sesgo n=100:   ", round(mean(vars_n100), 4), "\n")
```

```
## Sin sesgo n=100:    2.0019
```

```r
# Gráfico adicional mostrando la convergencia
tamaños <- c(10, 20, 100, 1000)
medias_sesgo <- c(mean(vars_sesgo_n10), mean(vars_sesgo_n20),
                  mean(vars_sesgo_n100), mean(vars_sesgo_n1000))

plot(tamaños, medias_sesgo, type="b", col="red", pch=19,
     main="Convergencia del estimador de varianza con sesgo",
     xlab="Tamaño de muestra", ylab="Media de varianza estimada",
     ylim=c(1.8, 2.1))
abline(h=varianza, lty=2, col="black", lwd=2)
```

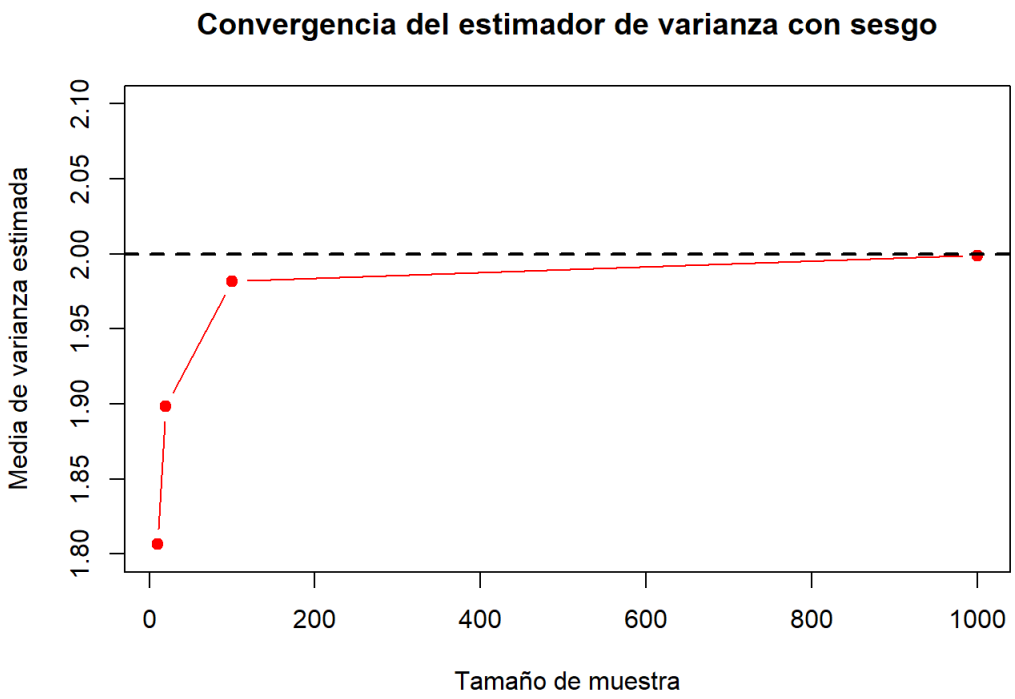


```
#


#son robsutos
random <- rnorm(100,mean=media,sd=sqrt(varianza))
mean(random)
```

```
## [1] 2.759244
```

```
var(random)
```

```
## [1] 2.114019
```

```
#que pasa si metemos un valor atípico (outlier)
random[1] <- 1000
mean(random)
```

```
## [1] 12.70939
```

```
var(random)
```

```
## [1] 9947.403
```

```
# mad, mediana

random <- rnorm(100,mean=media,sd=sqrt(varianza))
mean(random)
```

```
## [1] 2.991349
```

```
var(random)
```

```
## [1] 2.094337
```

```
#que pasa si metemos un valor atípico (outlier)
random[1] <- 1000
mean(random)
```

```
## [1] 12.98255
```

```
median(random)
```

```
## [1] 3.113083
```

```
sd(random)
```

```
## [1] 99.70901
```

```
mad(random)
```

```
## [1] 1.563836
```

```
sqrt(varianza) #el valor que queremos estimar
```

```
## [1] 1.414214
```

```
#cual es mas eficiente, la media o la mediana??

medianas_n20 <- rowMedians(B)
plot(density(medias_n20),col="blue")
lines(density(medianas_n20),col="red")
```

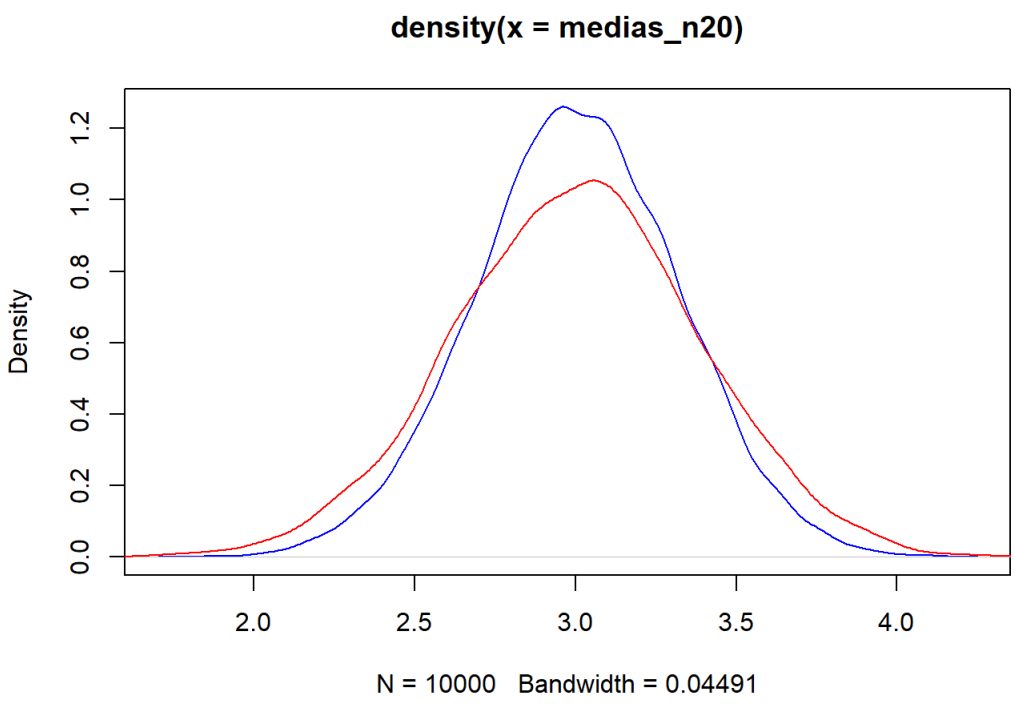


```
#intervalo de confianza de la media

x <- rnorm(100)
t.test(x)
```

```
##
##  One Sample t-test
##
## data:  x
## t = 0.8804, df = 99, p-value = 0.3808
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
##  -0.1092229  0.2834531
## sample estimates:
##  mean of x
## 0.08711513
```

```
#intervalo de confianza de la varianza
## no existe una funcion en R que lo haga

n <- length(x)
alpha <- 0.05
s2 <- var(x)

# Cuantiles de la chi-cuadrado
chi2_lower <- qchisq(1 - alpha/2, df = n - 1)
chi2_upper <- qchisq(alpha/2, df = n - 1)

# Intervalo de confianza para la varianza
lower_bound <- (n - 1) * s2 / chi2_lower
upper_bound <- (n - 1) * s2 / chi2_upper

cat("Intervalo de confianza del 95% para la varianza:\n")
```

```
## Intervalo de confianza del 95% para la varianza:
```

```
cat("(", lower_bound, ",", upper_bound, ")\n")
```

```
## ( 0.75479 , 1.321295 )
```

```
#
```

0. set working directory

```
# setwd("")
```

1.- cargar los datos

```
# Número de casos por provincia, fecha y tipo de detección
data1 <- read.csv('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/casos_tecnica_
provincia.csv',
                  header = T, sep = ',', stringsAsFactors = F,
                  check.names = F)

system.time(data1 <- read.csv('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/ca
sos_tecnica_provincia.csv',
                              header = T, sep = ',', stringsAsFactors = F,
                              check.names = F))
```

```
##    user  system elapsed
##    0.05    0.00    0.03
```

```
class(data1)
```

```
## [1] "data.frame"
```

```
dim(data1)
```

```
## [1] 32383     8
```

```
#veamos que fread es mas rapido (con estos datos no se nota, pero
#con data.frames mas grandes si que se nota)
system.time(data1_copia <- data.table::fread("C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Jua
n/Día 1/data/casos_tecnica_provincia.csv"))
```

```
##    user  system elapsed
##    0.02    0.00    0.04
```

```
class(data1_copia)
```

```
## [1] "data.table" "data.frame"
```

```
dim(data1_copia)
```

```
## [1] 32383     8
```

```
rm(data1_copia)


#cargar el resto de datos:


# Número de casos por comunidad autónoma, fecha y tipo de detección
data2 <- read.csv('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/casos_tecnica_
ccaa.csv',
                  header = T, sep = ',', stringsAsFactors = F,
                  check.names = F)

# Número de casos, hospitalizaciones y defunciones por fecha, edad y sexo
data3 <- data.table::fread('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/casos
_hosp_uci_def_sexo_edad_provres.csv',
                           header = T, sep = ',',
                           stringsAsFactors = F, check.names = F)
data3 <- as.data.frame(data3)
dim(data3)
```

```
## [1] 971490      8
```

```
# Read JSON files: aeropuertos:
myData1 <- fromJSON('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/aeropuertos_
2020.json')
output_dataframe1 <- as.data.frame(myData1$features)
data4 <- output_dataframe1$properties

myData2 <- fromJSON('C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/airlines_del
ays.json',flatten = TRUE)
data5 <- as.data.frame(myData2)
dim(data5)
```

```
## [1] 4408   24
```

```
#flatten = TRUE se pone para unir todas las columnas en un unico data.frame
#con flatten = FALSE (valor por defecto) data5 tendria 3 columnas y cada
#columnas seria un data.frame.


#datos estudiantes

data6 = read.csv(file="C:/Users/enriq/Desktop/Master/Data Science (MIB)/Clases Juan/Día 1/data/student-mat.csv",sep = ";")
head(data6)
```

```
##   school sex age address famsize Pstatus Medu Fedu     Mjob     Fjob     reason
## 1     GP   F  18       U     GT3       A    4    4  at_home  teacher     course
## 2     GP   F  17       U     GT3       T    1    1  at_home    other     course
## 3     GP   F  15       U     LE3       T    1    1  at_home    other      other
## 4     GP   F  15       U     GT3       T    4    2   health services       home
## 5     GP   F  16       U     GT3       T    3    3    other    other       home
## 6     GP   M  16       U     LE3       T    4    3 services    other reputation
##   guardian traveltime studytime failures schoolsup famsup paid activities
## 1   mother          2         2        0       yes     no   no         no
## 2   father          1         2        0        no    yes   no         no
## 3   mother          1         2        3       yes     no  yes         no
## 4   mother          1         3        0        no    yes  yes        yes
## 5   father          1         2        0        no    yes  yes         no
## 6   mother          1         2        0        no    yes  yes        yes
##   nursery higher internet romantic famrel freetime goout Dalc Walc health
## 1     yes    yes       no       no      4        3     4    1    1      3
## 2      no    yes      yes       no      5        3     3    1    1      3
## 3     yes    yes      yes       no      4        3     2    2    3      3
## 4     yes    yes      yes      yes      3        2     2    1    1      5
## 5     yes    yes       no       no      4        3     2    1    2      5
## 6     yes    yes      yes       no      5        4     2    1    2      5
##   absences G1 G2 G3
## 1        6  5  6  6
## 2        4  5  5  6
## 3       10  7  8 10
## 4        2 15 14 15
## 5        4  6 10 10
## 6       10 15 15 15
```

1.1 explorar los datos

```
#data1 = Número de casos por comunidad autónoma, fecha y tipo de detección
#data2 = Número de casos por comunidad autónoma, fecha y tipo de detección
#data3 = Número de casos, hospitalizaciones y defunciones por fecha, edad y sexo
#data4 = aeropuertos
#data5 = retrasos aeropuerto
#data6 = datos de estudiantes


dim(data1)
```

```
## [1] 32383     8
```

```
head(data1)
```

```
##   provincia_iso      fecha num_casos num_casos_prueba_pcr
## 1             A 2020-01-01         0                    0
## 2            AB 2020-01-01         0                    0
## 3            AL 2020-01-01         0                    0
## 4            AV 2020-01-01         0                    0
## 5             B 2020-01-01         0                    0
## 6            BA 2020-01-01         0                    0
##   num_casos_prueba_test_ac num_casos_prueba_ag num_casos_prueba_elisa
## 1                        0                   0                      0
## 2                        0                   0                      0
## 3                        0                   0                      0
## 4                        0                   0                      0
## 5                        0                   0                      0
## 6                        0                   0                      0
##   num_casos_prueba_desconocida
## 1                            0
## 2                            0
## 3                            0
## 4                            0
## 5                            0
## 6                            0
```

```
dim(data2)
```

```
## [1] 11609     8
```

```
head(data2)
```

```
##   ccaa_iso      fecha num_casos num_casos_prueba_pcr num_casos_prueba_test_ac
## 1       AN 2020-01-01         0                    0                         0
## 2       AR 2020-01-01         0                    0                         0
## 3       AS 2020-01-01         0                    0                         0
## 4       CB 2020-01-01         0                    0                         0
## 5       CE 2020-01-01         0                    0                         0
## 6       CL 2020-01-01         0                    0                         0
##   num_casos_prueba_ag num_casos_prueba_elisa num_casos_prueba_desconocida
## 1                   0                      0                            0
## 2                   0                      0                            0
## 3                   0                      0                            0
## 4                   0                      0                            0
## 5                   0                      0                            0
## 6                   0                      0                            0
```

```
dim(data3)
```

```
## [1] 971490      8
```

```
head(data3)
```

```
##   provincia_iso sexo grupo_edad      fecha num_casos num_hosp num_uci num_def
## 1             A    H        0-9 2020-01-01         0        0       0       0
## 2             A    H      10-19 2020-01-01         0        0       0       0
## 3             A    H      20-29 2020-01-01         0        0       0       0
## 4             A    H      30-39 2020-01-01         0        0       0       0
## 5             A    H      40-49 2020-01-01         0        0       0       0
## 6             A    H      50-59 2020-01-01         0        0       0       0
```

```
dim(data4)
```

```
## [1] 2033    8
```

```
head(data4)
```

```
##   geocode                             etiqueta granularidad gcd_iata gcd_icao
## 1 AE_OMAA   Aeropuerto Internacional Abu Dhabi  AEROPUERTOS      AUH     OMAA
## 2 AE_OMAD                 Aeropuerto de Batten  AEROPUERTOS      AZI     OMAD
## 3 AE_OMAJ Aeropuerto Internacional Jebel Dhana  AEROPUERTOS     <NA>     OMAJ
## 4 AE_OMAL      Aeropuerto Internacional Al Ain  AEROPUERTOS      AAN     OMAL
## 5 AE_OMAM                 Base aérea Al Ddafra  AEROPUERTOS      DHF     OMAM
## 6 AE_OMAW                   Base Aérea Sweihan  AEROPUERTOS     <NA>     OMAW
##   longitud  latitud    geohash
## 1 54.65110 24.43300 thqfgxgswc
## 2 54.45810 24.42830 thqdzpp1jt
## 3 52.61400 24.18740 thm3t70mg4
## 4 55.60920 24.26170 thrd12tqsk
## 5 54.54770 24.24820 thqccq0rvx
## 6 54.97417 24.52722 thr5dcncqv
```

```
class(data4$geocode)
```

```
## [1] "character"
```

```
dim(data5)
```

```
## [1] 4408   24
```

```
class(data5)
```

```
## [1] "data.frame"
```

```
colnames(data5)
```

```
##  [1] "Airport.Code"
##  [2] "Airport.Name"
##  [3] "Time.Label"
##  [4] "Time.Month"
##  [5] "Time.Month Name"
##  [6] "Time.Year"
##  [7] "Statistics.# of Delays.Carrier"
##  [8] "Statistics.# of Delays.Late Aircraft"
##  [9] "Statistics.# of Delays.National Aviation System"
## [10] "Statistics.# of Delays.Security"
## [11] "Statistics.# of Delays.Weather"
## [12] "Statistics.Carriers.Names"
## [13] "Statistics.Carriers.Total"
## [14] "Statistics.Flights.Cancelled"
## [15] "Statistics.Flights.Delayed"
## [16] "Statistics.Flights.Diverted"
## [17] "Statistics.Flights.On Time"
## [18] "Statistics.Flights.Total"
## [19] "Statistics.Minutes Delayed.Carrier"
## [20] "Statistics.Minutes Delayed.Late Aircraft"
## [21] "Statistics.Minutes Delayed.National Aviation System"
## [22] "Statistics.Minutes Delayed.Security"
## [23] "Statistics.Minutes Delayed.Total"
## [24] "Statistics.Minutes Delayed.Weather"
```

```
dim(data6)
```

```
## [1] 395  33
```

```
head(data6)
```

```
##   school sex age address famsize Pstatus Medu Fedu     Mjob     Fjob     reason
## 1     GP   F  18       U     GT3       A    4    4  at_home  teacher     course
## 2     GP   F  17       U     GT3       T    1    1  at_home    other     course
## 3     GP   F  15       U     LE3       T    1    1  at_home    other      other
## 4     GP   F  15       U     GT3       T    4    2   health services       home
## 5     GP   F  16       U     GT3       T    3    3    other    other       home
## 6     GP   M  16       U     LE3       T    4    3 services    other reputation
##   guardian traveltime studytime failures schoolsup famsup paid activities
## 1   mother          2         2        0       yes     no   no         no
## 2   father          1         2        0        no    yes   no         no
## 3   mother          1         2        3       yes     no  yes         no
## 4   mother          1         3        0        no    yes  yes        yes
## 5   father          1         2        0        no    yes  yes         no
## 6   mother          1         2        0        no    yes  yes        yes
##   nursery higher internet romantic famrel freetime goout Dalc Walc health
## 1     yes    yes       no       no      4        3     4    1    1      3
## 2      no    yes      yes       no      5        3     3    1    1      3
## 3     yes    yes      yes       no      4        3     2    2    3      3
## 4     yes    yes      yes      yes      3        2     2    1    1      5
## 5     yes    yes       no       no      4        3     2    1    2      5
## 6     yes    yes      yes       no      5        4     2    1    2      5
##   absences G1 G2 G3
## 1        6  5  6  6
## 2        4  5  5  6
## 3       10  7  8 10
## 4        2 15 14 15
## 5        4  6 10 10
## 6       10 15 15 15
```

#2.- operacion basica con dplyr #########

```
# ejemplo, queremos saber para cada comunidad autónoma cuantos casos
# hay en total.

#bucle
system.time({
  casos_por_provincia = data.frame(provincia_iso  = unique(data3$provincia_iso),
                                   total_casos = 0)
  for(iix in 1:nrow(casos_por_provincia)){
    prov <- casos_por_provincia$provincia_iso[iix]
    iid <- which(data3$provincia_iso == prov)
    casos_por_provincia$total_casos[iix] <- sum(data3$num_casos[iid])
  }
  casos_por_provincia <- casos_por_provincia[order(casos_por_provincia$total_casos,decreasing = TRUE),]
  head(casos_por_provincia)
})
```

```
##    user  system elapsed
##    0.22    0.00    0.22
```

```
system.time({casos_por_provincia <- data3 %>%
  group_by(provincia_iso) %>%
  summarise(
    total_casos = sum(num_casos),
    .groups = 'drop'
  ) %>%
  arrange(desc(total_casos))

head(casos_por_provincia)
})
```

```
##    user  system elapsed
##    0.02    0.00    0.02
```

```
#este código con un bucle es muy lento.
#poner %>% hace que sea más fácil de entender


#el mismo código sin usar %>%
arrange(summarise(group_by(data3,provincia_iso),total_casos=sum(num_casos),.groups = 'drop'),desc(total_c
asos))
```

```
## # A tibble: 53 × 2
##    provincia_iso total_casos
##    <chr>               <int>
##  1 M                  878764
##  2 B                  671946
##  3 V                  266524
##  4 A                  182352
##  5 SE                 170290
##  6 MA                 150302
##  7 MU                 138130
##  8 BI                 130924
##  9 Z                  114381
## 10 CA                 109143
## # ℹ 43 more rows
```

```
#en el examen y en el trabajo se va a evaluar eficiencia del código.
#por lo general se pueden evitar los bucles.
#y con dplyr se puede hacer el código más fácil de entender.
```

3.- tidy

```
#en nuestros datos ya tenemos el formato de observaciones x variables.
#vamos a trabajar con la base de datos billboard (está cargada en la libreria tidyverse)
#es decir, no hace falta hacer nada especial para cargar esta base de datos
dim(billboard)
```

```
## [1] 317  79
```

```
head(billboard)
```

```
## # A tibble: 6 × 79
##   artist      track date.entered   wk1   wk2   wk3   wk4   wk5   wk6   wk7   wk8
##   <chr>       <chr> <date>       <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
## 1 2 Pac       Baby… 2000-02-26      87    82    72    77    87    94    99    NA
## 2 2Ge+her     The … 2000-09-02      91    87    92    NA    NA    NA    NA    NA
## 3 3 Doors Do… Kryp… 2000-04-08      81    70    68    67    66    57    54    53
## 4 3 Doors Do… Loser 2000-10-21      76    76    72    69    67    65    55    59
## 5 504 Boyz    Wobb… 2000-04-15      57    34    25    17    17    31    36    49
## 6 98^0        Give… 2000-08-19      51    39    34    26    26    19     2     2
## # ℹ 68 more variables: wk9 <dbl>, wk10 <dbl>, wk11 <dbl>, wk12 <dbl>,
## #   wk13 <dbl>, wk14 <dbl>, wk15 <dbl>, wk16 <dbl>, wk17 <dbl>, wk18 <dbl>,
## #   wk19 <dbl>, wk20 <dbl>, wk21 <dbl>, wk22 <dbl>, wk23 <dbl>, wk24 <dbl>,
## #   wk25 <dbl>, wk26 <dbl>, wk27 <dbl>, wk28 <dbl>, wk29 <dbl>, wk30 <dbl>,
## #   wk31 <dbl>, wk32 <dbl>, wk33 <dbl>, wk34 <dbl>, wk35 <dbl>, wk36 <dbl>,
## #   wk37 <dbl>, wk38 <dbl>, wk39 <dbl>, wk40 <dbl>, wk41 <dbl>, wk42 <dbl>,
## #   wk43 <dbl>, wk44 <dbl>, wk45 <dbl>, wk46 <dbl>, wk47 <dbl>, wk48 <dbl>, …
```

```
#en este caso, hay dos variables que son:
# semana
# valor
#estos dos valores no están en el formato que queremos

billboard = billboard %>%
  pivot_longer(
    cols = starts_with("wk"),
    names_to = "week",
    values_to = "rank"
  )
head(billboard)
```

```
## # A tibble: 6 × 5
##   artist track                   date.entered week   rank
##   <chr>  <chr>                   <date>       <chr> <dbl>
## 1 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk1      87
## 2 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk2      82
## 3 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk3      72
## 4 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk4      77
## 5 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk5      87
## 6 2 Pac  Baby Don't Cry (Keep... 2000-02-26   wk6      94
```

```
#


head(data6$guardian)
```

```
## [1] "mother" "father" "mother" "mother" "father" "mother"
```

```
class(data6$guardian)
```

```
## [1] "character"
```

```
data6$guardian <- as.factor(data6$guardian)
head(data6$guardian)
```

```
## [1] mother father mother mother father mother
## Levels: father mother other
```

```
class(data6$guardian)
```

```
## [1] "factor"
```

```
head(data6$sex)
```

```
## [1] "F" "F" "F" "F" "F" "M"
```

```
data6$sex <- factor(data6$sex, levels = c("F","M"))
head(data6$sex)
```

```
## [1] F F F F F M
## Levels: F M
```

```
head(data6$freetime)
```

```
## [1] 3 3 3 2 3 4
```

```
data6$freetime <- as.factor(data6$freetime)
head(data6$freetime)
```

```
## [1] 3 3 3 2 3 4
## Levels: 1 2 3 4 5
```

4.- transform rows

4.1.- duplicados (distinict y count)

```
# duplicated(data1)  ->  #un valor para cada fila.
sum(duplicated(data1))
```

```
## [1] 0
```

```
sum(duplicated(data2))
```

```
## [1] 0
```

```
sum(duplicated(data3)) #lleva tiempo
```

```
## [1] 0
```

```
sum(duplicated(data4))
```

```
## [1] 0
```

```
sum(duplicated(data5))
```

```
## [1] 0
```

```
#para eliminar los duplicados, deberiamos quedarnos solo con los FALSE.

#todos
data4 <- data4 %>%
  distinct()

#quiero unicos
geocode <- data4 %>%
  distinct(geocode)

table(duplicated(geocode)) #es equivalente a hacer un unique
```

```
##
## FALSE
##  2032
```

```
geocode_gcd_icao <- data4 %>%
  distinct(geocode,gcd_icao)
head(geocode_gcd_icao)
```

```
##   geocode gcd_icao
## 1 AE_OMAA     OMAA
## 2 AE_OMAD     OMAD
## 3 AE_OMAJ     OMAJ
## 4 AE_OMAL     OMAL
## 5 AE_OMAM     OMAM
## 6 AE_OMAW     OMAW
```

```
geocode_gcd_icao_all_columns <- data4 %>%
  distinct(geocode,gcd_icao,.keep_all = TRUE)
head(geocode_gcd_icao_all_columns)
```

```
##   geocode                             etiqueta granularidad gcd_iata gcd_icao
## 1 AE_OMAA   Aeropuerto Internacional Abu Dhabi  AEROPUERTOS      AUH     OMAA
## 2 AE_OMAD                 Aeropuerto de Batten  AEROPUERTOS      AZI     OMAD
## 3 AE_OMAJ Aeropuerto Internacional Jebel Dhana  AEROPUERTOS     <NA>     OMAJ
## 4 AE_OMAL      Aeropuerto Internacional Al Ain  AEROPUERTOS      AAN     OMAL
## 5 AE_OMAM                 Base aérea Al Ddafra  AEROPUERTOS      DHF     OMAM
## 6 AE_OMAW                   Base Aérea Sweihan  AEROPUERTOS     <NA>     OMAW
##   longitud  latitud    geohash
## 1 54.65110 24.43300 thqfgxgswc
## 2 54.45810 24.42830 thqdzpp1jt
## 3 52.61400 24.18740 thm3t70mg4
## 4 55.60920 24.26170 thrd12tqsk
## 5 54.54770 24.24820 thqccq0rvx
## 6 54.97417 24.52722 thr5dcncqv
```

```
#¿Numero de vuelos en cada aeropuerto por año

data5 %>%
  dplyr::count(Airport.Code,Time.Year) %>%
  head()
```

```
##   Airport.Code Time.Year  n
## 1          ATL      2003  7
## 2          ATL      2004 12
## 3          ATL      2005 12
## 4          ATL      2006 12
## 5          ATL      2007 12
## 6          ATL      2008 12
```

```
## 4.2.- Eliminar NA values (filter) ########

any(is.na(data1))
```

```
## [1] TRUE
```

```
head(which(is.na(data1),arr.ind = TRUE))
```

```
##      row col
## [1,]  32   1
## [2,]  85   1
## [3,] 138   1
## [4,] 191   1
## [5,] 244   1
## [6,] 297   1
```

```
data1[32,]
```

```
##    provincia_iso      fecha num_casos num_casos_prueba_pcr
## 32          <NA> 2020-01-01         0                    0
##    num_casos_prueba_test_ac num_casos_prueba_ag num_casos_prueba_elisa
## 32                        0                   0                      0
##    num_casos_prueba_desconocida
## 32                            0
```

```
dim(data1)
```

```
## [1] 32383     8
```

```
any(is.na(data1$fecha))
```

```
## [1] FALSE
```

```
data1 = na.omit(data1)
dim(data1)
```

```
## [1] 31772     8
```

```
#na.omit elimina las filas donde hay NA
## en ML veréis que algunos casos se pueden inferir los NA para no perder datos.

data2 = na.omit(data2)
data3 = na.omit(data3)

#para data4 queremos eliminar filas con NA en una columan específica.
colnames(data4)[c(4,6,7,8)]
```

```
## [1] "gcd_iata" "longitud" "latitud"  "geohash"
```

```
#supongamos que solo nos interesa eliminar la fila si tiene NA en la columna "gcd_iata"

data4 <- data4 %>%
  filter(!is.na(gcd_iata))

any(is.na(data4$gcd_iata)) #hemos conseguido eliminar las filas donde habia NA en esta columna
```

```
## [1] FALSE
```

4.3.- cambiar orden filas (arrange)

```
#queremos que ordene las filas en funcion de un valor concreto

head(data4)
```

```
##   geocode                          etiqueta granularidad gcd_iata gcd_icao
## 1 AE_OMAA Aeropuerto Internacional Abu Dhabi  AEROPUERTOS      AUH     OMAA
## 2 AE_OMAD               Aeropuerto de Batten  AEROPUERTOS      AZI     OMAD
## 3 AE_OMAL    Aeropuerto Internacional Al Ain  AEROPUERTOS      AAN     OMAL
## 4 AE_OMAM               Base aérea Al Ddafra  AEROPUERTOS      DHF     OMAM
## 5 AE_OMDB     Aeropuerto Internacional Dubai  AEROPUERTOS      DXB     OMDB
## 6 AE_OMDM               Base Aérea Al Minhad  AEROPUERTOS      NHD     OMDM
##   longitud latitud    geohash
## 1  54.6511 24.4330 thqfgxgswc
## 2  54.4581 24.4283 thqdzpp1jt
## 3  55.6092 24.2617 thrd12tqsk
## 4  54.5477 24.2482 thqccq0rvx
## 5  55.3644 25.2528 thrrev5hhp
## 6  55.3662 25.0268 thrq7gurtv
```

```
data4_ordenado <- data4 %>%
  arrange(longitud)
head(data4_ordenado)
```

```
##   geocode                                     etiqueta granularidad gcd_iata
## 1 US_PANC Aeropuerto Internacional Ted Stevens Anchorage  AEROPUERTOS      ANC
## 2 US_PAMR                       Aeropuerto Merrill Field  AEROPUERTOS      MRI
## 3 US_PAED                           Base Aérea Elmendorf  AEROPUERTOS      EDF
## 4 PF_NTAA                  Aeropuerto Internacional Faa'a  AEROPUERTOS      PPT
## 5 US_PAFA              Aeropuerto Internacional Fairbanks  AEROPUERTOS      FAI
## 6 CA_CBX5                Aeropuerto de Tungsten (Cantung)  AEROPUERTOS      TNS
##   gcd_icao longitud  latitud    geohash
## 1     PANC -149.996  61.1744 bdvk4b2nxy
## 2     PAMR -149.844  61.2135 bdvknpwfmz
## 3     PAED -149.807  61.2510 bdvkrn3ugt
## 4     NTAA -149.607 -17.5537 2svs5s7w23
## 5     PAFA -147.856  64.8151 bewbernx36
## 6     CBX5 -128.203  61.9569 c5hb6wvmje
```

```r
data4_ordenado <- data4 %>%
  arrange(desc(longitud))
head(data4_ordenado)
```

```
##   geocode                                        etiqueta granularidad gcd_iata
## 1 FJ_NFNB                               Aeródromo de Levuka  AEROPUERTOS      LEV
## 2 NZ_NZRO                     Aeropuerto Regional de Rotorua  AEROPUERTOS      ROT
## 3 NZ_NZAA                  Aeropuerto Internacional Auckland  AEROPUERTOS      AKL
## 4 NC_NWWW               Aeropuerto Internacional La Tontouta  AEROPUERTOS      NOU
## 5 AU_YBBN                            Aeropuerto de Brisbane  AEROPUERTOS      BNE
## 6 AU_YSSY Aeropuerto Internacional Sydney Kingsford Smith  AEROPUERTOS      SYD
##   gcd_icao longitud  latitud    geohash
## 1     NFNB  178.759 -17.7111 ruz55zb36e
## 2     NZRO  176.317 -38.1092 rcjrhnqjgf
## 3     NZAA  174.792 -37.0081 rckm3qzshy
## 4     NWWW  166.213 -22.0146 rsn4y22ees
## 5     YBBN  153.117 -27.3842 r7huhqb7kz
## 6     YSSY  151.177 -33.9461 r3gwbh79xk
```

```r
#equivalente:
data4_ordenado <- data4[order(data4$longitud,decreasing = TRUE),]


#vamos a comparar los tiempos. Como es tan rapido no se puede medir con system.time
#para medir esto se puede utilizar microbenchmark

microbenchmark::microbenchmark(
  base = {
    data4_ordenado <- data4[order(data4$longitud,decreasing = TRUE),]
  },
  dplyr = {
    data4_ordenado <- data4 %>%
      arrange(desc(longitud))
  }
)
```

```
## Unit: microseconds
##   expr    min     lq     mean  median     uq     max neval
##   base  162.0  207.0  262.587  228.60  266.4   803.2   100
##  dplyr 1007.1 1111.7 1854.874 1239.25 1424.2 47796.0   100
```

```r
dim(data4)
```

```
## [1] 1689    8
```

```r
#si hacemos lo mismo con data3
dim(data3)
```

```
## [1] 953160      8
```

```r
microbenchmark::microbenchmark(
  base = {
    data3_ordenado <- data3[order(data3$grupo_edad,decreasing = TRUE),]
  },
  dplyr = {
    data3_ordenado <- data3 %>%
      arrange(desc(grupo_edad))

  },times = 10
)
```

```
## Unit: milliseconds
##   expr       min       lq       mean    median       uq       max neval
##   base 4053.3297 4069.910 4079.53319 4076.4498 4085.438 4120.8946    10
##  dplyr   24.5935   26.291   42.60803   34.4467   39.671  132.2938    10
```

4.4.- incorrect values

```
dim(data3)
```

```
## [1] 953160      8
```

```
unique(data3$sexo)
```

```
## [1] "H"  "M"  "NC"
```

```
unique(data3$grupo_edad)
```

```
##  [1] "0-9"   "10-19" "20-29" "30-39" "40-49" "50-59" "60-69" "70-79" "80+"
## [10] "NC"
```

```
data3 <- data3[-which(data3$sexo =='NC'),]
data3 <- data3[-which(data3$grupo_edad =='NC'),]
dim(data3)
```

```
## [1] 571896      8
```

5.- transform columns

5.1.- add new columns (mutate)

```
dim(data2)
```

```
## [1] 11609     8
```

```
head(data2)
```

```
##   ccaa_iso      fecha num_casos num_casos_prueba_pcr num_casos_prueba_test_ac
## 1       AN 2020-01-01         0                    0                        0
## 2       AR 2020-01-01         0                    0                        0
## 3       AS 2020-01-01         0                    0                        0
## 4       CB 2020-01-01         0                    0                        0
## 5       CE 2020-01-01         0                    0                        0
## 6       CL 2020-01-01         0                    0                        0
##   num_casos_prueba_ag num_casos_prueba_elisa num_casos_prueba_desconocida
## 1                   0                      0                            0
## 2                   0                      0                            0
## 3                   0                      0                            0
## 4                   0                      0                            0
## 5                   0                      0                            0
## 6                   0                      0                            0
```

```
head(data3)
```

```
##   provincia_iso sexo grupo_edad      fecha num_casos num_hosp num_uci num_def
## 1             A    H        0-9 2020-01-01         0        0       0       0
## 2             A    H      10-19 2020-01-01         0        0       0       0
## 3             A    H      20-29 2020-01-01         0        0       0       0
## 4             A    H      30-39 2020-01-01         0        0       0       0
## 5             A    H      40-49 2020-01-01         0        0       0       0
## 6             A    H      50-59 2020-01-01         0        0       0       0
```

```
#añadir año, mes y dia en data2 y data3

data2$fecha[1]
```

```
## [1] "2020-01-01"
```

```
year(data2$fecha[1])
```

```
## [1] 2020
```

```
day(data2$fecha[1])
```

```
## [1] 1
```

```
month(data2$fecha[1])
```

```
## [1] 1
```

```
data2_n <- data2 %>%
  mutate(year = year(fecha),
         day = day(fecha),
         month = month(fecha))

head(data2_n)
```

```
##   ccaa_iso      fecha num_casos num_casos_prueba_pcr num_casos_prueba_test_ac
## 1       AN 2020-01-01         0                    0                        0
## 2       AR 2020-01-01         0                    0                        0
## 3       AS 2020-01-01         0                    0                        0
## 4       CB 2020-01-01         0                    0                        0
## 5       CE 2020-01-01         0                    0                        0
## 6       CL 2020-01-01         0                    0                        0
##   num_casos_prueba_ag num_casos_prueba_elisa num_casos_prueba_desconocida year
## 1                   0                      0                            0 2020
## 2                   0                      0                            0 2020
## 3                   0                      0                            0 2020
## 4                   0                      0                            0 2020
## 5                   0                      0                            0 2020
## 6                   0                      0                            0 2020
##   day month
## 1   1     1
## 2   1     1
## 3   1     1
## 4   1     1
## 5   1     1
## 6   1     1
```

```
#con base:
data2_n <- data2
data2_n$year <- year(data2$fecha)
data2_n$dat <- day(data2$fecha)
data2_n$month <- month(data2$fecha)
```

5.2.- select

```
colnames(data3)
```

```
## [1] "provincia_iso" "sexo"          "grupo_edad"    "fecha"
## [5] "num_casos"     "num_hosp"      "num_uci"       "num_def"
```

```
data3_new <- data3 %>%
  select(provincia_iso,fecha,grupo_edad)

head(data3_new)
```

```
##   provincia_iso      fecha grupo_edad
## 1             A 2020-01-01        0-9
## 2             A 2020-01-01      10-19
## 3             A 2020-01-01      20-29
## 4             A 2020-01-01      30-39
## 5             A 2020-01-01      40-49
## 6             A 2020-01-01      50-59
```

5.3.- change column names (rename)

```
head(data3_new)
```

```
##   provincia_iso      fecha grupo_edad
## 1             A 2020-01-01        0-9
## 2             A 2020-01-01      10-19
## 3             A 2020-01-01      20-29
## 4             A 2020-01-01      30-39
## 5             A 2020-01-01      40-49
## 6             A 2020-01-01      50-59
```

```
data3_new <- data3_new %>%
  rename(year_month = fecha)
head(data3_new)
```

```
##   provincia_iso year_month grupo_edad
## 1             A 2020-01-01        0-9
## 2             A 2020-01-01      10-19
## 3             A 2020-01-01      20-29
## 4             A 2020-01-01      30-39
## 5             A 2020-01-01      40-49
## 6             A 2020-01-01      50-59
```

5.4.- cambiar orden (relocate)

```
head(data3)
```

```
##   provincia_iso sexo grupo_edad      fecha num_casos num_hosp num_uci num_def
## 1             A    H        0-9 2020-01-01         0        0       0       0
## 2             A    H      10-19 2020-01-01         0        0       0       0
## 3             A    H      20-29 2020-01-01         0        0       0       0
## 4             A    H      30-39 2020-01-01         0        0       0       0
## 5             A    H      40-49 2020-01-01         0        0       0       0
## 6             A    H      50-59 2020-01-01         0        0       0       0
```

```
data3_new <- data3 %>%
  relocate(fecha:num_casos,.after = num_uci)
head(data3_new)
```

```
##   provincia_iso sexo grupo_edad num_hosp num_uci      fecha num_casos num_def
## 1             A    H        0-9        0       0 2020-01-01         0       0
## 2             A    H      10-19        0       0 2020-01-01         0       0
## 3             A    H      20-29        0       0 2020-01-01         0       0
## 4             A    H      30-39        0       0 2020-01-01         0       0
## 5             A    H      40-49        0       0 2020-01-01         0       0
## 6             A    H      50-59        0       0 2020-01-01         0       0
```

5.- groups

5.1.- incorrect values string patterns (group_by, summarise)

```r
#son casos de datos que no estan completos
## estan todos los meses completos??

tabla_mes_dia <- data1 %>%
  mutate(
    year = year(fecha),
    month = month(fecha),
    day = day(fecha)
  ) %>%
  group_by(year,month) %>%
  summarise(
    max_day = max(day),
    .groups = 'drop'
  )

print(tabla_mes_dia,n=Inf) #queremos ver todo
```

```
## # A tibble: 21 × 3
##     year month max_day
##    <dbl> <dbl>   <int>
##  1  2020     1      31
##  2  2020     2      29
##  3  2020     3      31
##  4  2020     4      30
##  5  2020     5      31
##  6  2020     6      30
##  7  2020     7      31
##  8  2020     8      31
##  9  2020     9      30
## 10  2020    10      31
## 11  2020    11      30
## 12  2020    12      31
## 13  2021     1      31
## 14  2021     2      28
## 15  2021     3      31
## 16  2021     4      30
## 17  2021     5      31
## 18  2021     6      30
## 19  2021     7      31
## 20  2021     8      31
## 21  2021     9       2
```

```r
#en data1 se puede observar que septiembre del 2021 no está completo
#comprobar esto para data1 y data2

# eliminar los meses que no estén completos en data1

data1_new <- data1[-!str_detect(string = data1$fecha,pattern = "2021-09"),]
#en data1_new hemos quitado año 2021 y mes 09.
```

6.- factors

```r
head(data6)
```

```
##   school sex age address famsize Pstatus Medu Fedu     Mjob     Fjob     reason
## 1     GP   F  18       U     GT3       A    4    4  at_home  teacher     course
## 2     GP   F  17       U     GT3       T    1    1  at_home    other     course
## 3     GP   F  15       U     LE3       T    1    1  at_home    other      other
## 4     GP   F  15       U     GT3       T    4    2   health services       home
## 5     GP   F  16       U     GT3       T    3    3    other    other       home
## 6     GP   M  16       U     LE3       T    4    3 services    other reputation
##   guardian traveltime studytime failures schoolsup famsup paid activities
## 1   mother          2         2        0       yes     no   no         no
## 2   father          1         2        0        no    yes   no         no
## 3   mother          1         2        3       yes     no  yes         no
## 4   mother          1         3        0        no    yes  yes        yes
## 5   father          1         2        0        no    yes  yes         no
## 6   mother          1         2        0        no    yes  yes        yes
##   nursery higher internet romantic famrel freetime goout Dalc Walc health
## 1     yes    yes       no       no      4        3     4    1    1      3
## 2      no    yes      yes       no      5        3     3    1    1      3
## 3     yes    yes      yes       no      4        3     2    2    3      3
## 4     yes    yes      yes      yes      3        2     2    1    1      5
## 5     yes    yes       no       no      4        3     2    1    2      5
## 6     yes    yes      yes       no      5        4     2    1    2      5
##   absences G1 G2 G3
## 1        6  5  6  6
## 2        4  5  5  6
## 3       10  7  8 10
## 4        2 15 14 15
## 5        4  6 10 10
## 6       10 15 15 15
```

```
class(data6$age)
```

```
## [1] "integer"
```

```
#por lo general las variables numericas no dan problemas
#por defecto son numericas

class(data6$sex)
```

```
## [1] "factor"
```

```
#las categoricas dan problemas. Por defecto son tipo "character"

data6$sex <-  as.factor(data6$sex)
head(data6$sex)
```

```
## [1] F F F F F M
## Levels: F M
```

```
#otra forma de hacerlo:
data6$sex <- factor(data6$sex,levels = c("M","F"))
head(data6$sex) #podemos elegir el orden de los levels.
```

```
## [1] F F F F F M
## Levels: M F
```

```
#problema viene si los levels son numeros
class(data6$freetime)
```

```
## [1] "factor"
```

```
head(data6$freetime)
```

```
## [1] 3 3 3 2 3 4
## Levels: 1 2 3 4 5
```

```
#esto es una categoria ordenada
data6$freetime <- as.factor(data6$freetime)
head(data6$freetime)
```

```
## [1] 3 3 3 2 3 4
## Levels: 1 2 3 4 5
```

EJERCICIOS

```
#datos de la libreria nycflights13::flights
dim(flights)
```

```
## [1] 336776     19
```

```
head(flights)
```

```
## # A tibble: 6 × 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013     1     1      517            515         2      830            819
## 2  2013     1     1      533            529         4      850            830
## 3  2013     1     1      542            540         2      923            850
## 4  2013     1     1      544            545        -1     1004           1022
## 5  2013     1     1      554            600        -6      812            837
## 6  2013     1     1      554            558        -4      740            728
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

ejercicio 1

ejercicio 1.1

```
class(flights)
```

```
## [1] "tbl_df"     "tbl"        "data.frame"
```

```
flights %>%
  count(dep_delay >=2)
```

```
## # A tibble: 3 × 2
##   `dep_delay >= 2`      n
##   <lgl>             <int>
## 1 FALSE            208139
## 2 TRUE             120382
## 3 NA                 8255
```

```
flights %>%
  filter(dep_delay >=2) %>%
  count()
```

```
## # A tibble: 1 × 1
##        n
##    <int>
## 1 120382
```

ejercicio 1.2

```r
head(flights)
```

```
## # A tibble: 6 × 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013     1     1      517            515         2      830            819
## 2  2013     1     1      533            529         4      850            830
## 3  2013     1     1      542            540         2      923            850
## 4  2013     1     1      544            545        -1     1004           1022
## 5  2013     1     1      554            600        -6      812            837
## 6  2013     1     1      554            558        -4      740            728
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```r
sum(flights$dest %in% c("IAH", "HOU"))
```

```
## [1] 9313
```

ejercicio 1.3

```r
head(flights, 20)
```

```
## # A tibble: 20 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     1      517            515         2      830            819
##  2  2013     1     1      533            529         4      850            830
##  3  2013     1     1      542            540         2      923            850
##  4  2013     1     1      544            545        -1     1004           1022
##  5  2013     1     1      554            600        -6      812            837
##  6  2013     1     1      554            558        -4      740            728
##  7  2013     1     1      555            600        -5      913            854
##  8  2013     1     1      557            600        -3      709            723
##  9  2013     1     1      557            600        -3      838            846
## 10  2013     1     1      558            600        -2      753            745
## 11  2013     1     1      558            600        -2      849            851
## 12  2013     1     1      558            600        -2      853            856
## 13  2013     1     1      558            600        -2      924            917
## 14  2013     1     1      558            600        -2      923            937
## 15  2013     1     1      559            600        -1      941            910
## 16  2013     1     1      559            559         0      702            706
## 17  2013     1     1      559            600        -1      854            902
## 18  2013     1     1      600            600         0      851            858
## 19  2013     1     1      600            600         0      837            825
## 20  2013     1     1      601            600         1      844            850
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```r
class(flights$carrier)
```

```
## [1] "character"
```

```r
head(flights$carrier)
```

```
## [1] "UA" "UA" "AA" "B6" "DL" "UA"
```

```r
sum(flights$carrier %in% c('AA', 'UA', 'DL'))
```

```
## [1] 139504
```

ejercicio 1.4

```
head(flights)
```

```
## # A tibble: 6 × 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013     1     1      517            515         2      830            819
## 2  2013     1     1      533            529         4      850            830
## 3  2013     1     1      542            540         2      923            850
## 4  2013     1     1      544            545        -1     1004           1022
## 5  2013     1     1      554            600        -6      812            837
## 6  2013     1     1      554            558        -4      740            728
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
sum(flights$month %in% c(7, 8, 9))
```

```
## [1] 86326
```

```
flights %>%
  filter(month %in% c(7, 8, 9)) %>%
  nrow()
```

```
## [1] 86326
```

ejercicio 1.5

```
head(flights)
```

```
## # A tibble: 6 × 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013     1     1      517            515         2      830            819
## 2  2013     1     1      533            529         4      850            830
## 3  2013     1     1      542            540         2      923            850
## 4  2013     1     1      544            545        -1     1004           1022
## 5  2013     1     1      554            600        -6      812            837
## 6  2013     1     1      554            558        -4      740            728
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(arr_time > 120 & dep_delay <= 0) %>%
  nrow()
```

```
## [1] 198323
```

ejercicio 1.6

```
head(flights)
```

```
## # A tibble: 6 × 19
##    year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##   <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
## 1  2013     1     1      517            515         2      830            819
## 2  2013     1     1      533            529         4      850            830
## 3  2013     1     1      542            540         2      923            850
## 4  2013     1     1      544            545        -1     1004           1022
## 5  2013     1     1      554            600        -6      812            837
## 6  2013     1     1      554            558        -4      740            728
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  filter(dep_delay >= 60 & (dep_delay - arr_delay) > 30) %>%
  nrow()
```

```
## [1] 1844
```

ejercicio 2

```
flights %>%
  arrange(desc(dep_delay)) %>%
  head(10)
```

```
## # A tibble: 10 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1     9      641            900      1301     1242           1530
##  2  2013     6    15     1432           1935      1137     1607           2120
##  3  2013     1    10     1121           1635      1126     1239           1810
##  4  2013     9    20     1139           1845      1014     1457           2210
##  5  2013     7    22      845           1600      1005     1044           1815
##  6  2013     4    10     1100           1900       960     1342           2211
##  7  2013     3    17     2321            810       911      135           1020
##  8  2013     6    27      959           1900       899     1236           2226
##  9  2013     7    22     2257            759       898      121           1026
## 10  2013    12     5      756           1700       896     1058           2020
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  arrange(dep_time) %>%
  head(10)
```

```
## # A tibble: 10 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1    13        1           2249        72      108           2357
##  2  2013     1    31        1           2100       181      124           2225
##  3  2013    11    13        1           2359         2      442            440
##  4  2013    12    16        1           2359         2      447            437
##  5  2013    12    20        1           2359         2      430            440
##  6  2013    12    26        1           2359         2      437            440
##  7  2013    12    30        1           2359         2      441            437
##  8  2013     2    11        1           2100       181      111           2225
##  9  2013     2    24        1           2245        76      121           2354
## 10  2013     3     8        1           2355         6      431            440
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

ejercicio 3

```
flights %>%
  arrange(air_time) %>%
  head(10)
```

```
## # A tibble: 10 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1    16     1355           1315        40     1442           1411
##  2  2013     4    13      537            527        10      622            628
##  3  2013    12     6      922            851        31     1021            954
##  4  2013     2     3     2153           2129        24     2247           2224
##  5  2013     2     5     1303           1315       -12     1342           1411
##  6  2013     2    12     2123           2130        -7     2211           2225
##  7  2013     3     2     1450           1500       -10     1547           1608
##  8  2013     3     8     2026           1935        51     2131           2056
##  9  2013     3    18     1456           1329        87     1533           1426
## 10  2013     3    19     2226           2145        41     2305           2246
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

```
flights %>%
  arrange(distance/air_time) %>%
  head(10)
```

```
## # A tibble: 10 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     1    28     1917           1825        52     2118           1935
##  2  2013     6    29      755            800        -5     1035            909
##  3  2013     8    28      932            940        -8     1116           1051
##  4  2013     1    30     1037            955        42     1221           1100
##  5  2013    11    27      556            600        -4      727            658
##  6  2013     5    21      558            600        -2      721            657
##  7  2013    12     9     1540           1535         5     1720           1656
##  8  2013     6    10     1356           1300        56     1646           1414
##  9  2013     7    28     1322           1325        -3     1612           1432
## 10  2013     4    11     1349           1345         4     1542           1453
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```

ejercicio 4

```
daily_flights <- flights %>%
  group_by(month, day) %>%
  summarise(num_flights = n(), .groups = 'drop')
total_days_with_flights <- nrow(daily_flights)
flight_every_day <- total_days_with_flights == 365
flight_every_day
```

```
## [1] TRUE
```

ejercicio 5

```
flights %>%
  arrange(desc(distance)) %>%
  select(flight, distance) %>%
  head(10)
```

```
## # A tibble: 10 × 2
##    flight distance
##     <int>    <dbl>
##  1     51     4983
##  2     51     4983
##  3     51     4983
##  4     51     4983
##  5     51     4983
##  6     51     4983
##  7     51     4983
##  8     51     4983
##  9     51     4983
## 10     51     4983
```

```
flights %>%
  arrange(distance)%>%
  head(10)
```

```
## # A tibble: 10 × 19
##     year month   day dep_time sched_dep_time dep_delay arr_time sched_arr_time
##    <int> <int> <int>    <int>          <int>     <dbl>    <int>          <int>
##  1  2013     7    27       NA            106        NA       NA            245
##  2  2013     1     3     2127           2129        -2     2222           2224
##  3  2013     1     4     1240           1200        40     1333           1306
##  4  2013     1     4     1829           1615       134     1937           1721
##  5  2013     1     4     2128           2129        -1     2218           2224
##  6  2013     1     5     1155           1200        -5     1241           1306
##  7  2013     1     6     2125           2129        -4     2224           2224
##  8  2013     1     7     2124           2129        -5     2212           2224
##  9  2013     1     8     2127           2130        -3     2304           2225
## 10  2013     1     9     2126           2129        -3     2217           2224
## # ℹ 11 more variables: arr_delay <dbl>, carrier <chr>, flight <int>,
## #   tailnum <chr>, origin <chr>, dest <chr>, air_time <dbl>, distance <dbl>,
## #   hour <dbl>, minute <dbl>, time_hour <dttm>
```