Data Science

Introduction to Hypothesis Testing

Dr. Juan A. Ferrer-Bonsoms jafhernandez@unav.es

Tecnun Universidad de Navarra | ESCUELA DE INGENIERÍA INGENIARITZA ESKOLA SCHOOL OF ENGINEERING

Hypothesis Testing

Un test de hipótesis (también denominado contraste de hipótesis o prueba de significación) es un procedimiento para juzgar si una propiedad que se supone en una población estadística es compatible con lo observado en una muestra de dicha población.

El objetivo del test de hipótesis es evaluar si el resultado observado en un experimento (una muestra de la población) es **estadísticamente significativo** en la población.

- **Hipótesis nula** (H_0): Es la suposición general o posición por defecto de que no hay relación entre dos condiciones o no hay asocación entre grupos. Esta hipótesis se considera cierta hasta que se demuestre lo contrario. Por lo general, es lo contrario a lo que queremos demostrar.
- **Hipótesis alternativa** (H_1): Es la hipótesis que afirma que si hay una diferencia entre dos condiciones o que si hay relación entre grupos. Por lo general, es lo que queremos demostar.

- **P-value**: Probabilidad de obtener un resultado al menos tan extremo como el resultado realmente observado suponiendo que la hipótesis nula sea correcta. No es la probabilidad de que la hipótesis nula sea cierta.

Hypothesis Testing

Jugador 1: 6 – 6 – 6 – 5 – 6 – 6 – 6 – 5 – 6 – 6

Jugador 2: 3 – 2 – 4 – 1 – 6 – 5 – 3 – 4 – 1 – 2

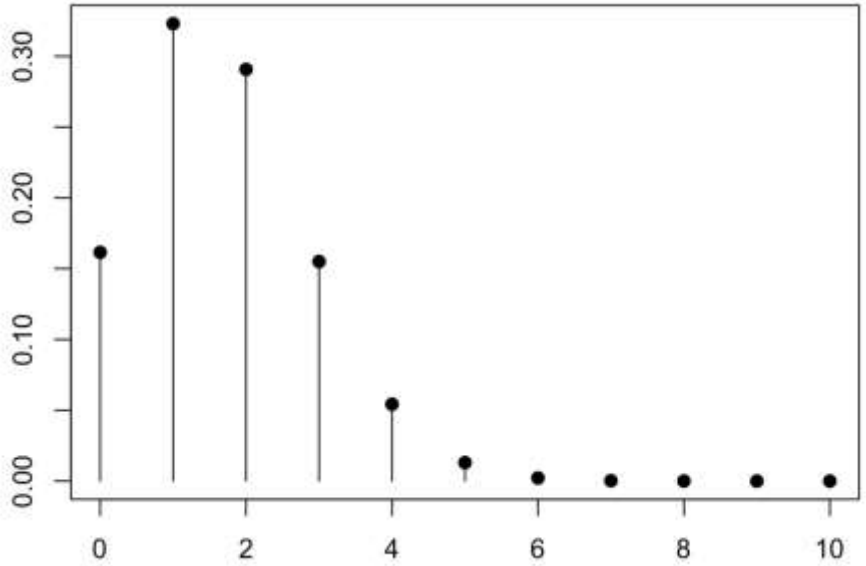

¿El dado del jugador 1 está trucado?

Ho = el dado del jugador 1 no está trucado -> p = 1/6
H1 = el dado del jugador 1 está trucado para que el 6 sagla más veces -> p > 1/6

p.value = probabilidad de encontrar un valor igual o más extremo al observado si se cumple la Ho

$$p.value = P(B(n=10,p) >= 8|H_0) = P(B(n=10,p=1/6) >= 8) = \cdots = 1.944889e-05$$

Hypothesis Testing

$$H_o : \mu_x = \mu_y$$
$$H_1 : \mu_x \neq \mu_y$$

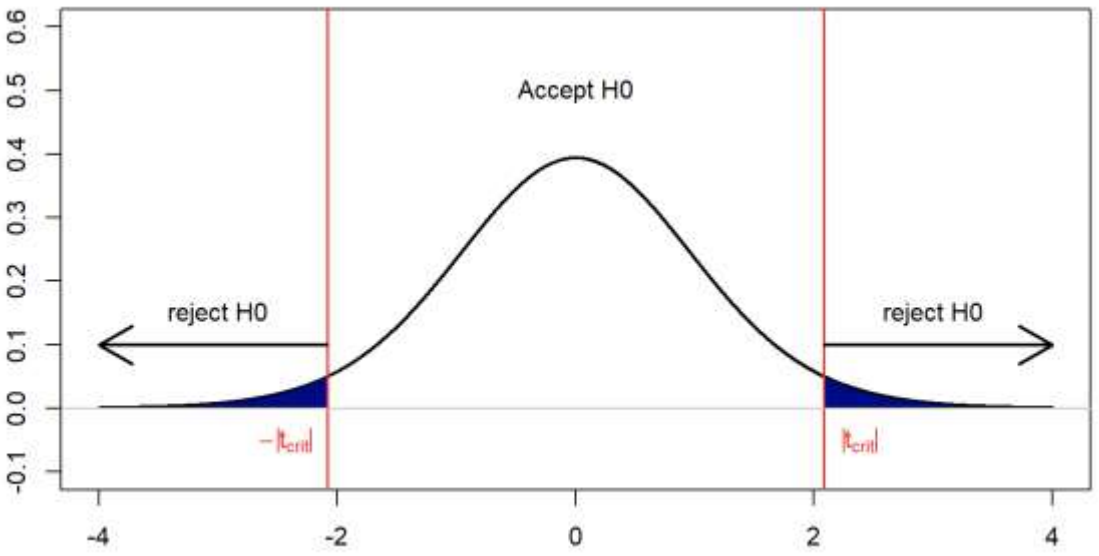

Test a dos colas

$$H_o : \mu_x = \mu_y$$
$$H_1 : \mu_x > \mu_x$$

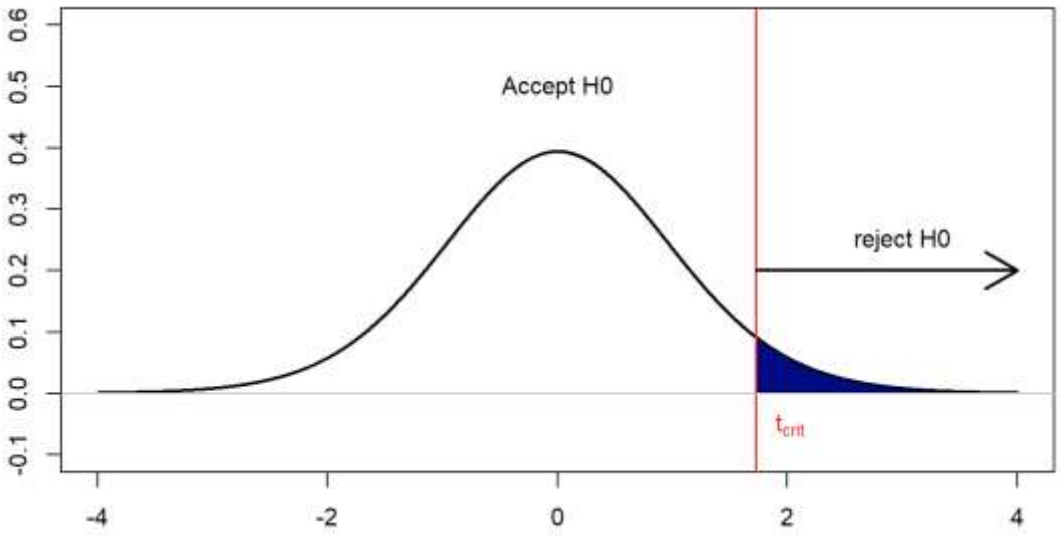

Test a una cola

Hypothesis Testing

$$H_o : \mu_x = \mu_y$$
$$H_1 : \mu_x \neq \mu_y$$

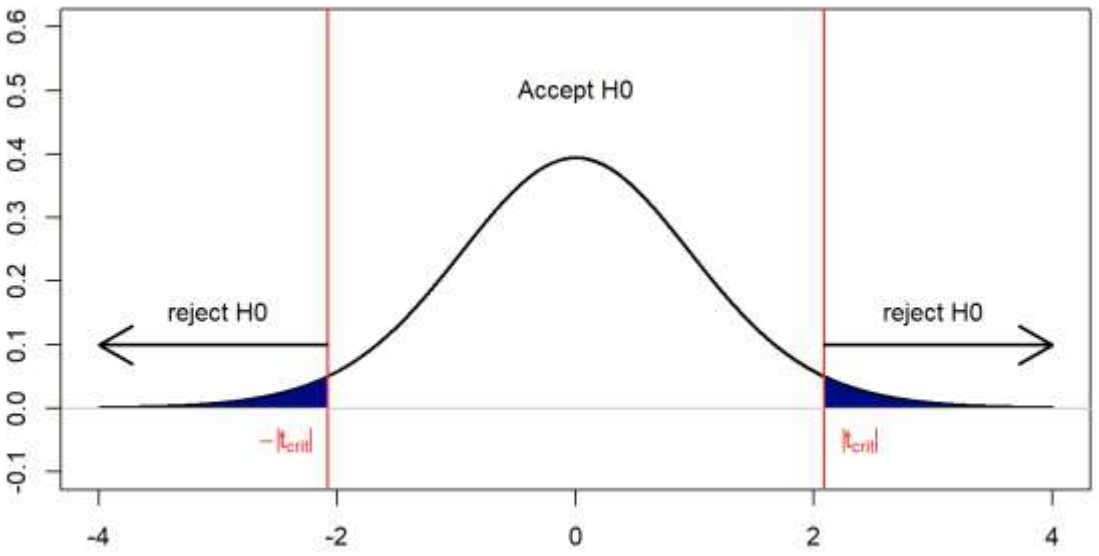

Test a dos colas

$$H_o : \mu_x = \mu_y$$
$$H_1 : \mu_x < \mu_y$$

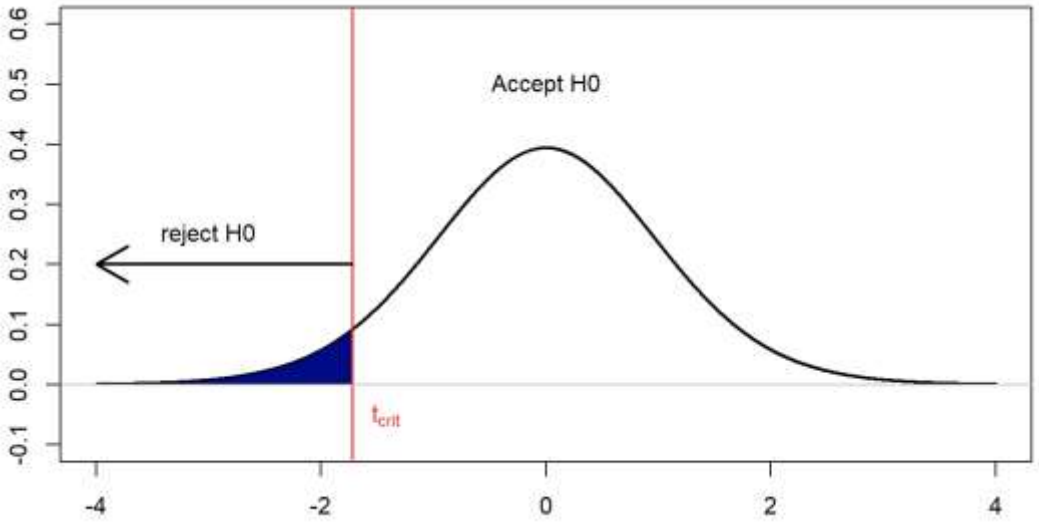

Test a una cola

Popular Hypothesis Tests

- t.test
- F.test
- Anova test

- Permutation test
- Bootstrap
- Test de Bondad de ajuste

- Hipergométrica / Test de Fisher
- Test chi-cuadrado
- Binomial test
- Poisson Binomial (Rediscover) (no lo vamos a ver)
- Tablas de contingencia mayores a 2x2

- Test de Wilcoxon (Mann-Whitney)
- Kruskal Wallis

1.- Definir H_0 y H_1.

2.- Establecer un valor α para rechazar la hipótesis nula. Por lo general, $\alpha = 0.05$.

3.- Determinar el test estadístico a utilizar.

4.- Calcular el **p-value** y rechazar o no la hipótesis nula.

t-test

Objetivo: comparar la localización de dos poblaciones.

$$X_i \sim N(\mu_X, \sigma_X), \quad i = 1, \ldots, n_x$$
$$Y_i \sim N(\mu_Y, \sigma_Y), \quad i = 1, \ldots, n_y$$

$$E(\overline{X} - \overline{Y}) = E(\overline{X}) - E(\overline{Y}) = \mu_X - \mu_Y$$

$$VAR(\overline{X} - \overline{Y}) = \sigma^2_{\overline{X}} + \sigma^2_{\overline{Y}}$$

$$\sigma^2_{diff} = \sigma^2_{\overline{X}} + \sigma^2_{\overline{Y}}$$

$$T_0 = \frac{(\overline{X} - \overline{Y}) - (\mu_X - \mu_Y)}{\hat{\sigma}_{diff}} \sim t_{n-2}$$

$$\hat{\sigma}^2_{diff} = \frac{(n_X - 1)s_X^2 + (n_Y - 1)s_Y^2}{(n_X + n_Y - 2)}\left(\frac{n_X + n_Y}{n_X n_Y}\right)$$

$$T_0 \big| H_0 = \frac{(\overline{X} - \overline{Y})}{\hat{\sigma}_{diff}} \sim t_{n-2}$$

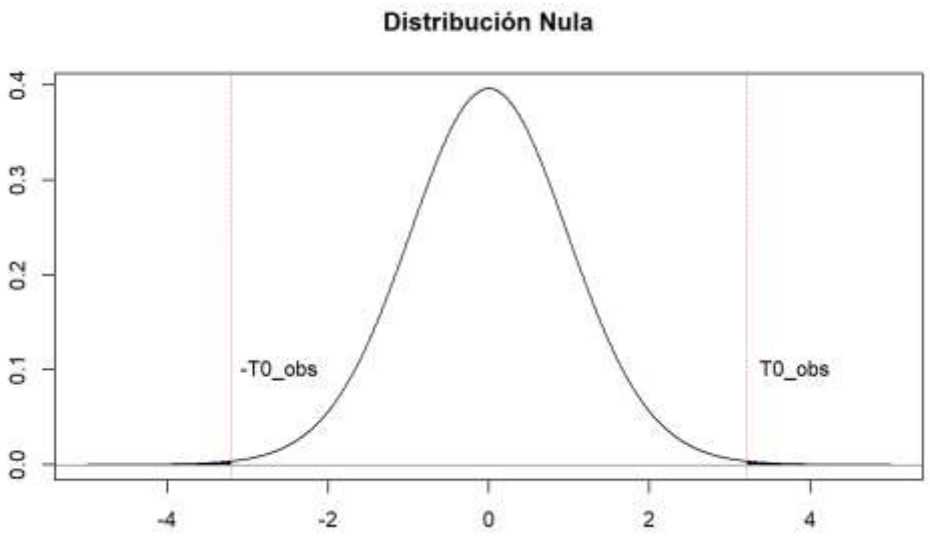

t-test

Objetivo: comparar la localización de dos poblaciones.

$$X_i \sim N(\mu_X, \sigma_X), \quad i = 1, \ldots, n_x$$
$$Y_i \sim N(\mu_Y, \sigma_Y), \quad i = 1, \ldots, n_y$$

$$E(\overline{X} - \overline{Y}) = E(\overline{X}) - E(\overline{Y}) = \mu_X - \mu_Y$$

$$VAR(\overline{X} - \overline{Y}) = \sigma^2_{\overline{X}} + \sigma^2_{\overline{Y}}$$

$$\sigma^2_{diff} = \sigma^2_{\overline{X}} + \sigma^2_{\overline{Y}}$$

$$p - value = P\left(|t_{n-2}| \geq \left|\frac{(\overline{x} - \overline{y}) - (\mu_x - \mu_y)}{\hat{\sigma_{diff}}}\right| \middle| H_0\right)$$

$$p - value = P\left(|t_{n-2}| \geq \left|\frac{(\overline{x} - \overline{y})}{\hat{\sigma_{diff}}}\right|\right)$$

$$p - value = P\left(t_{n-2} \geq |t_{observado}|\right) + P\left(t_{n-2} \leq -|t_{observado}|\right)$$

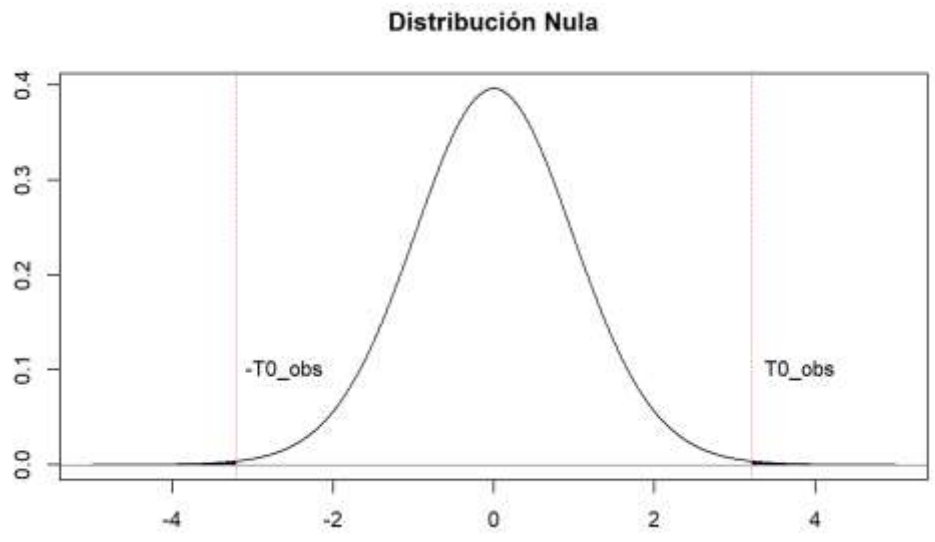

t-test

$$p-value = P\left(|t_{n-2}| \geq \left|\frac{(\overline{x}-\overline{y})-(\mu_x-\mu_y)}{\hat{\sigma_{diff}}}\right| \middle| H_0\right)$$

$$p-value = P\left(|t_{n-2}| \geq \left|\frac{(\overline{x}-\overline{y})}{\hat{\sigma_{diff}}}\right|\right)$$

$$p-value = P\left(t_{n-2} \geq |t_{observado}|\right) + P\left(t_{n-2} \leq -|t_{observado}|\right)$$

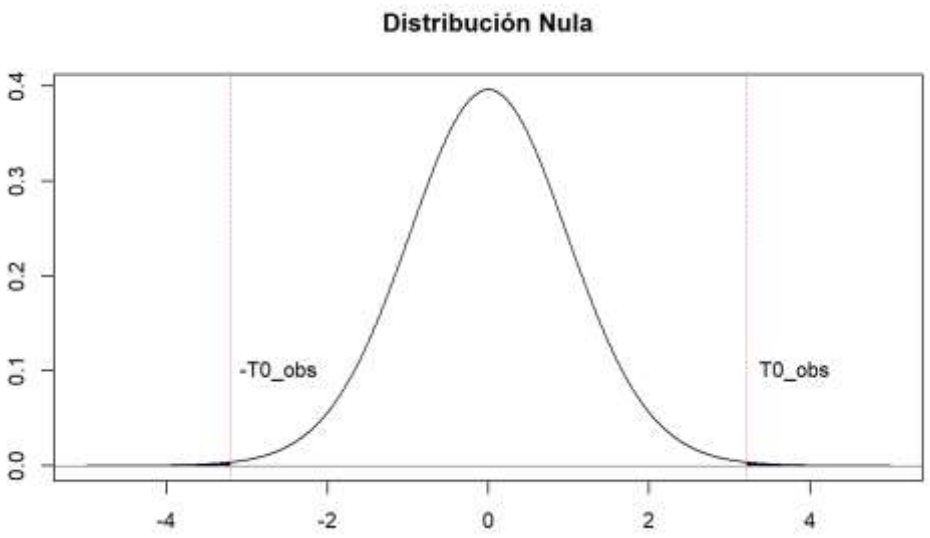


```
x = rnorm(20,mean=2,sd=1)
t.test(x) #one-sample t.test

y = rnorm(24,mean=4,sd=2)
t.test(x,y,alternative = "two.sided") #dos colas
t.test(x,y,alternative = "greater") # x > y
t.test(x,y,alternative = "less") # x < y
```

t-test

$$\overline{X} - \overline{Y} - t_{\alpha/2,n-2}\ \hat{\sigma}_{diff} \leq \mu_X - \mu_Y \leq \overline{X} - \overline{Y} + t_{\alpha/2,n-2}\ \hat{\sigma}_{diff}$$

```
> t.test(x,y)

Welch Two Sample t-test

data: x and y
t = -3.5104, df = 29.676, p-value = 0.001451
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-3.285227 -0.867896
sample estimates:
mean of x mean of y
1.847973 3.924535
```

¿Relación entre p.value y el intervalo de confianza?

t-test pareado

$$T_0 = \frac{(\overline{X} - \overline{Y}) - (\mu_X - \mu_Y)}{\hat{\sigma_{diff}}} \sim t_{n-2}$$

$$\hat{\sigma^2_{diff}} = \frac{(n_X - 1)s_X^2 + (n_Y - 1)s_Y^2}{(n_X + n_Y - 2)}\left(\frac{n_X + n_Y}{n_X n_Y}\right)$$

$$\overline{d} = \frac{1}{n}\sum_{i=1}^{n}(x_i - y_i) = \frac{1}{n}\sum_{i=1}^{n}(d_i)$$

$$S_d^2 = \frac{1}{n-1}\sum_{i=1}^{n}(d_i - \overline{d})^2$$

$$\frac{\overline{d}}{\sqrt{\frac{S_d^2}{n}}} \sim t_{n-1}$$

es equivalente a un one-sample t.test

Tenemos información de cada "item" en las dos condiciones que queremos comparar

```
#el orden de x e y tiene que ser coherente
x = rnorm(20,mean=2,sd=1)
y = rnorm(20,mean=4,sd=2)
t.test(x,y,paired = TRUE)
```

F-test

objetivo: comparar la varianza de dos poblaciones

$$H_0: \frac{\sigma_1^2}{\sigma_2^2} = 1$$
$$H_1: \frac{\sigma_1^2}{\sigma_2^2} \neq 1$$

$$F_{n-1,m-1} = \frac{s_1^2}{s_2^2}$$

Fisher–Snedecor distribution

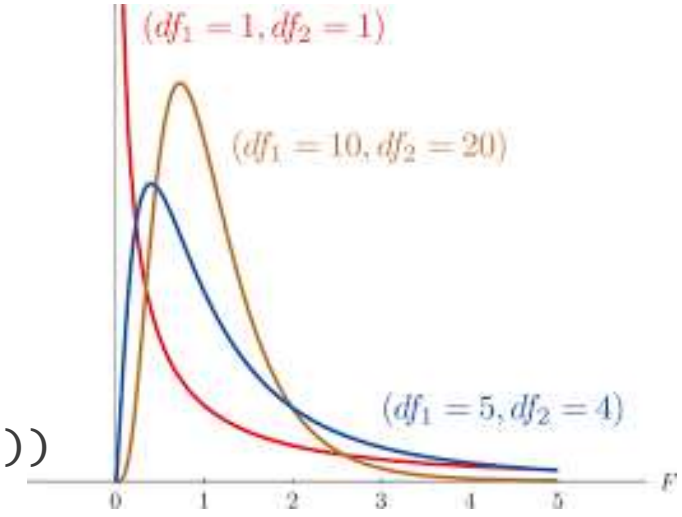


```
# F tests for equal variances in R
?var.test
var.test(x, y, alternative = c('two.sided'))
```

Bartlett test of variances:

compare several groups.

```
# Variance tests in R
?bartlett.test
z = rnorm(20,mean=0,sd=1)
zz <- c(x,y,z)
g <- as.factor(c(rep('g1', 20), rep('g2', 24),rep('g3', 20)))
bartlett.test(zz, g, alternative = c('two.sided'))
```

Anova

Objetivo: comparar localización de varias poblaciones (más de 2)

$$SSE = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(x_{ij} - \overline{x_i}\right)^2$$

I = número de grupos
n_i = número de muestras del grupo i
x_i = media del grupo i

$$SSG = \sum_{i=1}^{I} n_i \left(\overline{x_i} - \overline{x}\right)^2$$

I = número de grupos
n_i = número de muestras del grupo i
$\overline{x_i}$ = media del grupo i
$\overline{x}$ = media global

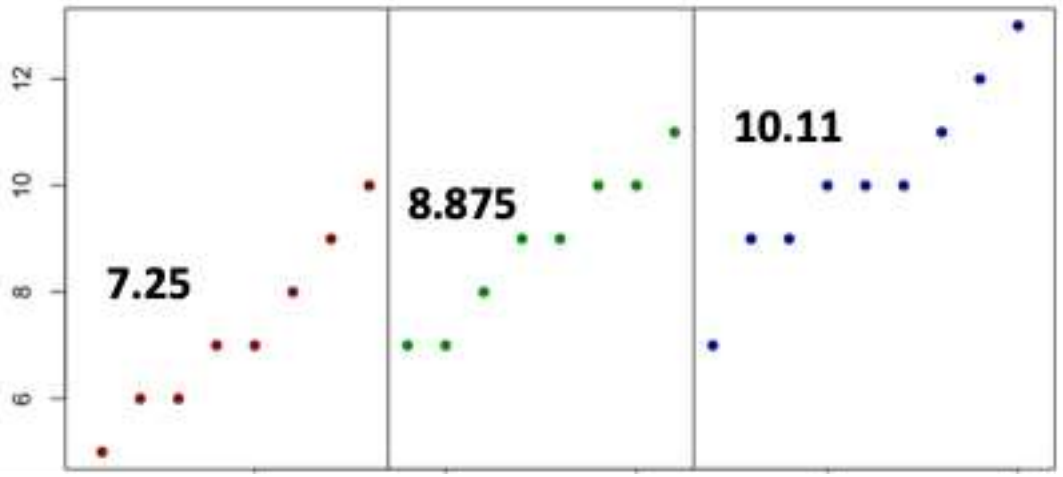

$$TSS = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(x_{ij} - \overline{x}\right)^2 = \sum_{i=1}^{N} \left(x_i - \overline{x}\right)^2$$

N = número total de datos
$\overline{x}$ = media global

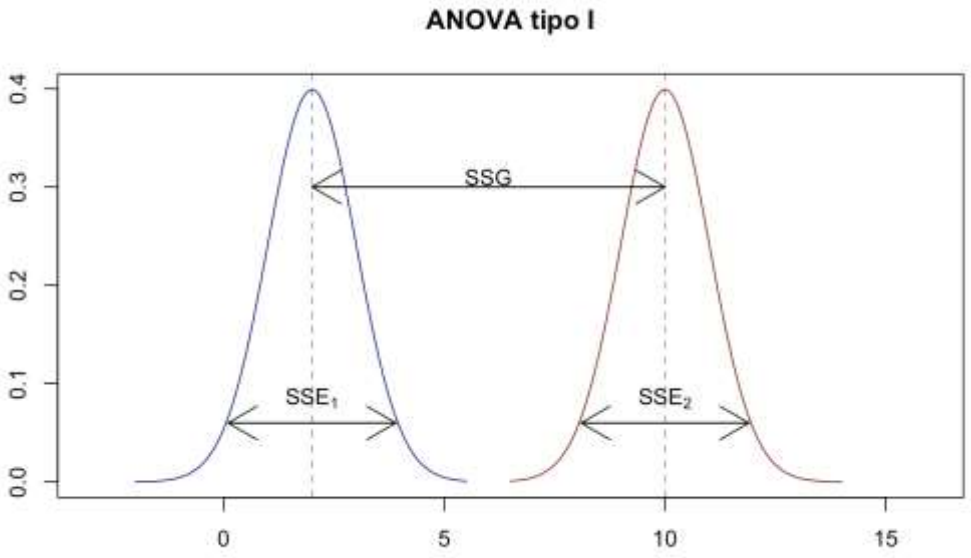

Anova

Objetivo: comparar localización de varias poblaciones (más de 2)

$$SSE = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(x_{ij} - \overline{x_i}\right)^2$$

I = número de grupos
n_i = número de muestras del grupo i
x_i = media del grupo i

$$SSG = \sum_{i=1}^{I} n_i \left(\overline{x_i} - \overline{x}\right)^2$$

I = número de grupos
n_i = número de muestras del grupo i
$\overline{x_i}$ = media del grupo i
$\overline{x}$ = media global

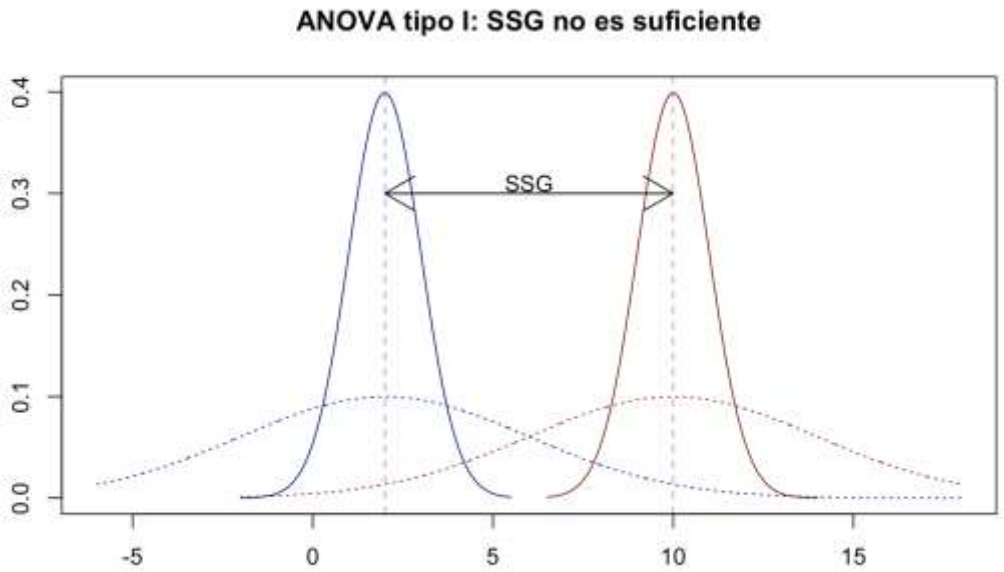

$$TSS = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(x_{ij} - \overline{x}\right)^2 = \sum_{i=1}^{N} \left(x_i - \overline{x}\right)^2$$

N = número total de datos
$\overline{x}$ = media global

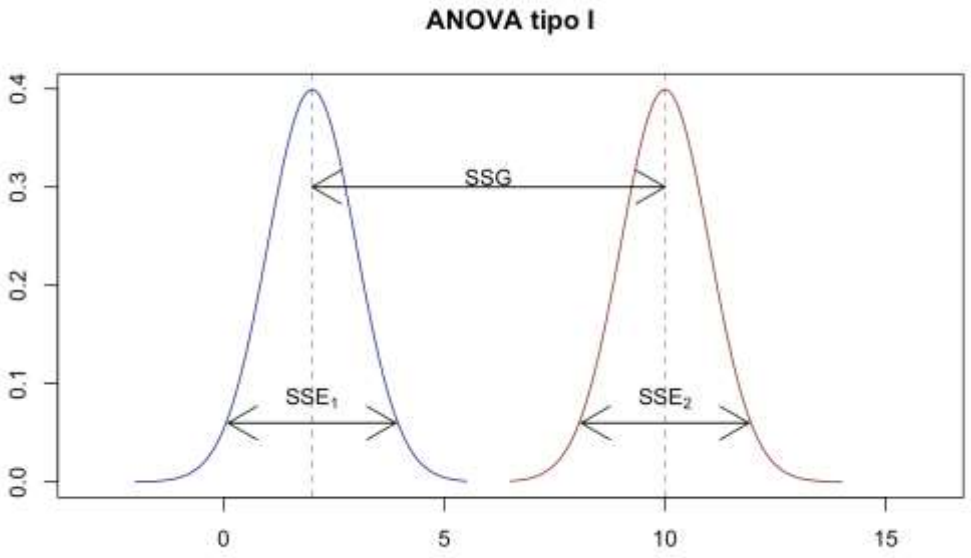

Anova

Objetivo: comparar localización de varias poblaciones (más de 2)

$$F_0 = \frac{N-I}{I-1}\frac{SSG}{SSE} = \frac{SSG/(I-1)}{SSE/(N-I)} \sim F_{m,n}$$

donde

$m = I - 1$ i.e. número de grupos -1

$n = N - I$ i.e. número de datos - número de grupos

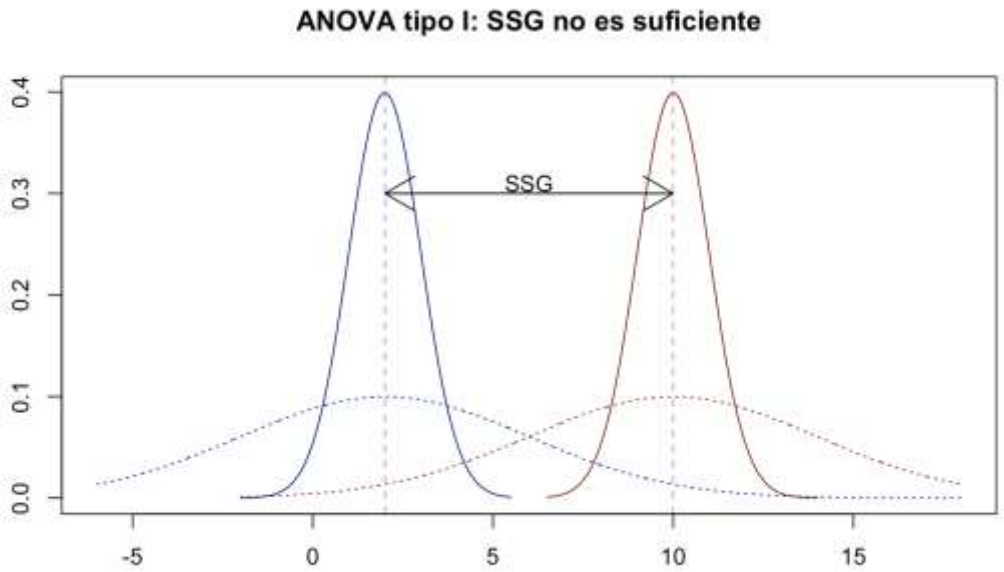

Ho : todas las medias son iguales

- Si hay dos grupos es equivalente a un t.test a dos colas.
- No tiene dirección: si hay significancia estadística sabremos que hay un grupo diferente, pero no sabemos cual ni en que dirección

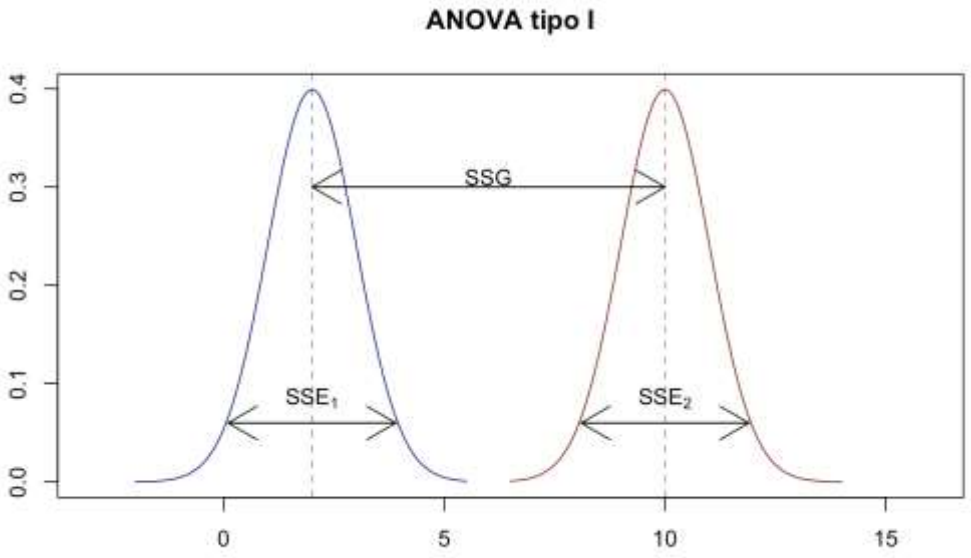

Anova

Objetivo: comparar localización de varias poblaciones (más de 2)

$$F_0 = \frac{N-I}{I-1}\frac{SSG}{SSE} = \frac{SSG/(I-1)}{SSE/(N-I)} \sim F_{m,n}$$

donde

$m = I - 1$ i.e. número de grupos -1

$n = N - I$ i.e. número de datos - número de grupos

```
#anova
x = rnorm(20,mean=2,sd=1)
y = rnorm(20,mean=4,sd=2)
z = rnorm(20,mean=0,sd=1)
zz = c(x,y,z)
g <- as.factor(c(rep('g1', 20), rep('g2', 20),rep('g3', 20)))
model = aov(zz~g)
anova(model)
```

Ho : todas las medias son iguales

```
#t.test y anova son equivalente
t.test(x,y,var.equal = TRUE)
anova(aov(c(x,y) ~ as.factor(c(rep('g1', 20), rep('g2',
20)))))
```

- Si hay dos grupos es equivalente a un t.test a dos colas.
- No tiene dirección: si hay significancia estadística sabremos que hay un grupo diferente, pero no sabemos cual ni en que dirección

Test paramétricos

- **t.test**
- **F.test**
- **Anova test**

El T-test se basa en los principios de normalidad y homogeneidad de la varianza.

¿Es sensato usar esas hipótesis? En muchos casos a los que me he enfrentado, es poco probable que tanto el control como el estado de enfermedad tengan la misma varianza. A pesar de esto, los resultados del t-test son razonablemente buenos.

Existen alternativas al T-test que pueden mejorar los resultados en ciertos campos de aplicación. Sin embargo, son algo más difíciles de entender y aplicar e incluyen conocimiento a priori..

Mientras las muestras de cada grupo sean grandes y las varianzas similares, el T-test es robusto, es decir, sigue siendo bueno, aunque no se cumplan exactamente los supuestos.

```
> t.test(x,y,var.equal = FALSE)#por defecto

Welch Two Sample t-test

data: x and y
t = -3.5104, df = 29.676, p-value = 0.001451
alternative hypothesis: true difference in means is not
equal to 0
95 percent confidence interval:
-3.285227 -0.867896
sample estimates:
mean of x mean of y
1.847973 3.924535
```

```
> t.test(x,y,var.equal = TRUE)

Two Sample t-test

data: x and y
t = -3.5104, df = 38, p-value = 0.00117
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
-3.274098 -0.879025
sample estimates:
mean of x mean of y
1.847973 3.924535
```

Test No paramétricos

- **t.test** → Test de Wilcoxon (Mann-Whitney)
- **F.test** → test de Levene (no lo vamos a ver)
- **Anova test** → Kruskal Wallis

- Los tests no paramétricos se utilizan cuando se no se cumplen las suposiciones de normalidad, homogeneidad de varianzas, presencia de outliers, etc.

- **Ventaja** es la **robustez**: requieren menos suposiciones, son resistentes a valores atípicos.

- **Desventaja**: tienen **menor potencia estadística** que los tests paramétricos cuando las suposiciones de estos últimos se cumplen.

Wilcoxon test

- Es la versión equivalente no paramétrica del T-test.
- Se realiza una transformación de rango en los datos.
  - Se cambia cada dato por su posición en un vector ordenado.
- Sobre estos datos se realiza un cálculo "t-statistic like".
  - Este estadístico no sigue una distribución t pero si el número de datos es grande (por ejemplo > 10), se aproxima bastante.
  - El cálculo exacto del p-value de la distribución se realiza para muestras pequeñas.

```
#t.test vs wilcoxon
x = rnorm(20,mean=2,sd=1)
y = rnorm(20,mean=4,sd=2)
x[1] = 20
boxplot(x,y)
t.test(x,y)
wilcox.test(x,y)
```

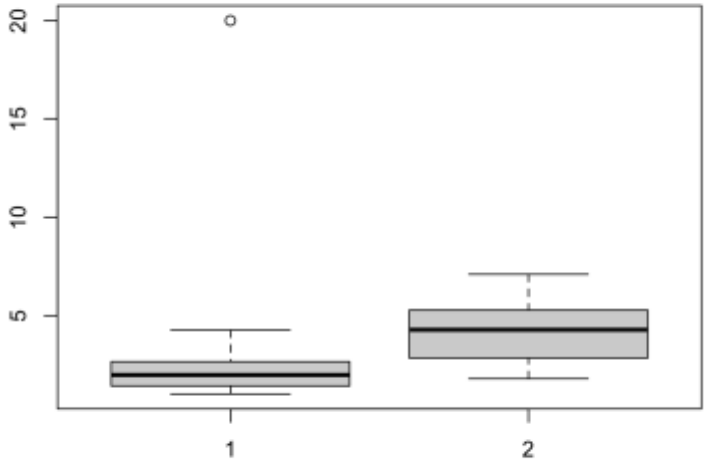

Kruskal Wallis test

- Datos transformados según el rango.
- La estadística es también SSG sobre SSE (corregida por los DOF correspondientes).
  - El p-value se modifica (para un número reducido de muestras) en función de la nueva distribución implícita (ya no es normal).
  - No se necesita transformación para un gran número de muestras.
- Robustez frente a outliers.

```r
#anova vs k-w
x = rnorm(20,mean=2,sd=1)
y = rnorm(20,mean=4,sd=2)
z = rnorm(20,mean=6,sd=1)
x[1] = 35
y[1] = 0;y[2] = 40
z[1] = 1
boxplot(x,y,z)
zz = c(x,y,z)
g <- as.factor(c(rep('g1', 20), rep('g2', 20),rep('g3', 20)))
model = aov(zz~g)
anova(model)
kruskal.test(zz ~ g)
```

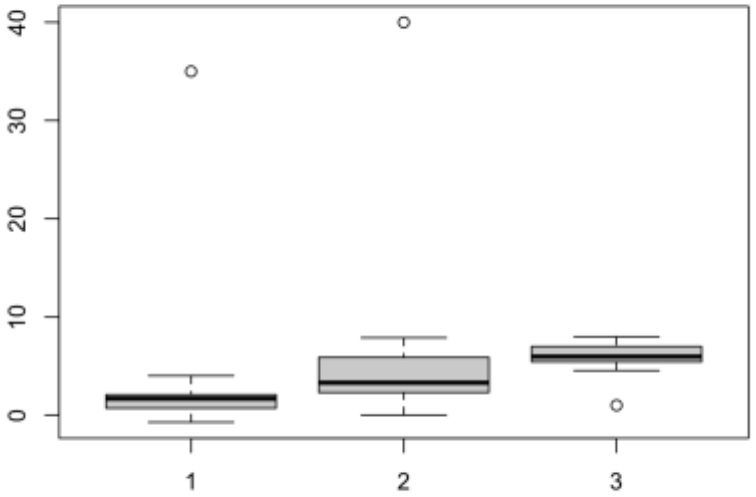

Popular Hypothesis Tests

- **t.test**
- **F.test**
- **Anova test**

- Permutation test
- Bootstrap
- Test de Bondad de ajuste

- **Hipergométrica / Test de Fisher**
- **Test chi-cuadrado**
- **Binomial test**
- **Poisson Binomial (Rediscover) (no lo vamos a ver)**
- **Tablas de contingencia mayores a 2x2**

Valores categóricos

- **Test de Wilcoxon (Mann-Whitney)**
- **Kruskal Wallis**

Test de Fisher

Objetivo: observar si en un grupo hay sobrerepresentación de una clase.

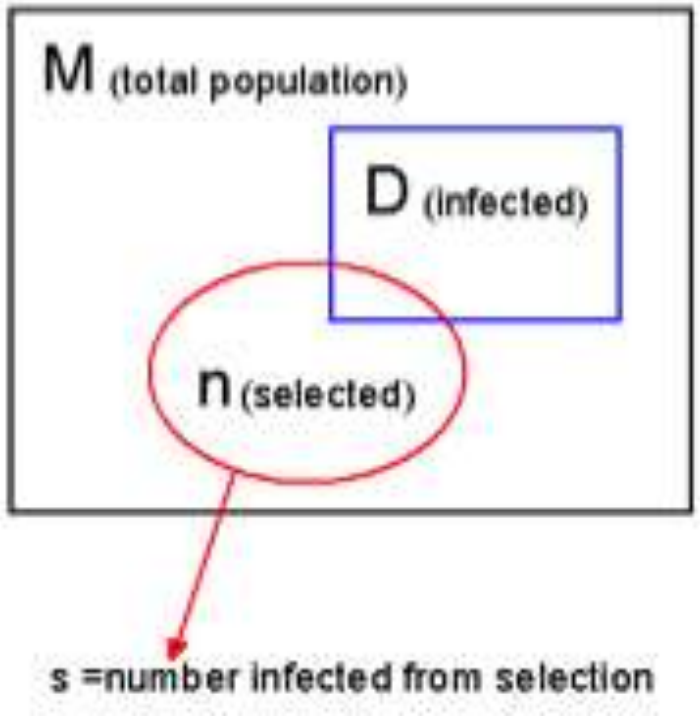

Contigency Table	Target	Non-target	Total
Infected	S	D-S	D
Non-infected	n-S	M-D-n+S	M-D
Total	n-S	M-n	M-D

H_0: *Independence of variables* $\quad$ *x: H(M,D,n,s)*

H_1: *Dependency of variables*

$$p(X \geq s) = \sum_{s}^{n-s} \frac{\binom{D}{s}\binom{M-D}{n-s}}{\binom{M}{n}}$$

Test de Fisher

```
# Hypergeometric test
M=100 #personas en total
D=40 #son del barsa
n=20 #selcciono 20 catalanes
s=15 #observo que de lo 20, 15 son del barsa
x <- s:n
Pvalue <- sum(dhyper(x, D, M-D, n))
Pvalue
```

Contigency Table	Target	Non-target	Total
Infected	S	D-S	D
Non-infected	n-S	M-D-n+S	M-D
Total	n-S	M-n	M-D

H_0: *Independence of variables* $\quad$ x: $H(M,D,n,s)$

H_1: *Dependency of variables*

```
# Test.Fisherct1 <- matrix(nrow = 2, ncol = 2)
ct1 =matrix(0,nrow=2,ncol=2)
colnames(ct1) <- c('Barsa','No Barsa')
rownames(ct1) <- c('Catalan','No Catalan')
ct1[1,1] <- s;
ct1[1,2] <- D-s;
ct1[2,1] <- n-s;
ct1[2,2] <- M-D-n+s;
fisher.test(ct1,alternative = "greater")
```

$$p(X \geq s) = \sum_{s}^{n-s} \frac{\binom{D}{s}\binom{M-D}{n-s}}{\binom{M}{n}}$$

Test de Chi-Cuadrado

Es equivalente al test de Fisher.

Contigency Table	Target	Non-target	Total
Infected	S	D-S	D
Non-infected	n-S	M-D-n+S	M-D
Total	n-S	M-n	M-D

$$\chi^2 = \sum_{i=1}^{n} \frac{(O_i - E_i)^2}{E_i}$$

```
ct1 =matrix(0,nrow=2,ncol=2)
colnames(ct1) <- c('Barsa','No Barsa')
rownames(ct1) <- c('Catalan','No Catalan')
ct1[1,1] <- s;
ct1[1,2] <- D-s;
ct1[2,1] <- n-s;
ct1[2,2] <- M-D-n+s;
chisq.test(ct1)
```

Test de Fisher mejor cuando hay pocos datos.

Test Chi-cuadrado:

- para muestras grandes
- Tablas de contingencia mayores a 2x2

Binomial test

Binomial test

- Association test
- Null hypothesis: no association and the process follows a binomial random variable:
- **x**: **B(n,p)**
- where **n** is the sample size and **p** is the probability of success.

```
# Calculating binomial test: coin loaded
binom.test(8,10,0.5, alternative= 'greater')


# Paul the Octopus correctly predicted 8 out of 8
matches
# in 2010 World Cup
binom.test(8,8,0.5, alternative= 'greater')
```

Popular Hypothesis Tests

- t.test
- F.test
- Anova test

- Hipergométrica / Test de Fisher
- Test chi-cuadrado
- Binomial test
- Poisson Binomial (Rediscover) (no lo vamos a ver)
- Tablas de contingencia mayores a 2x2

- Test de Wilcoxon (Mann-Whitney)
- Kruskal Wallis

- **Permutation test**
- **Bootstrap**
- **Test de Bondad de ajuste**

Permutation Tests

El "permutation test" (test de permutación) es un método de re-muestreo no paramétrico utilizado en estadística para determinar si las diferencias observadas entre dos o más grupos son estadísticamente significativas.

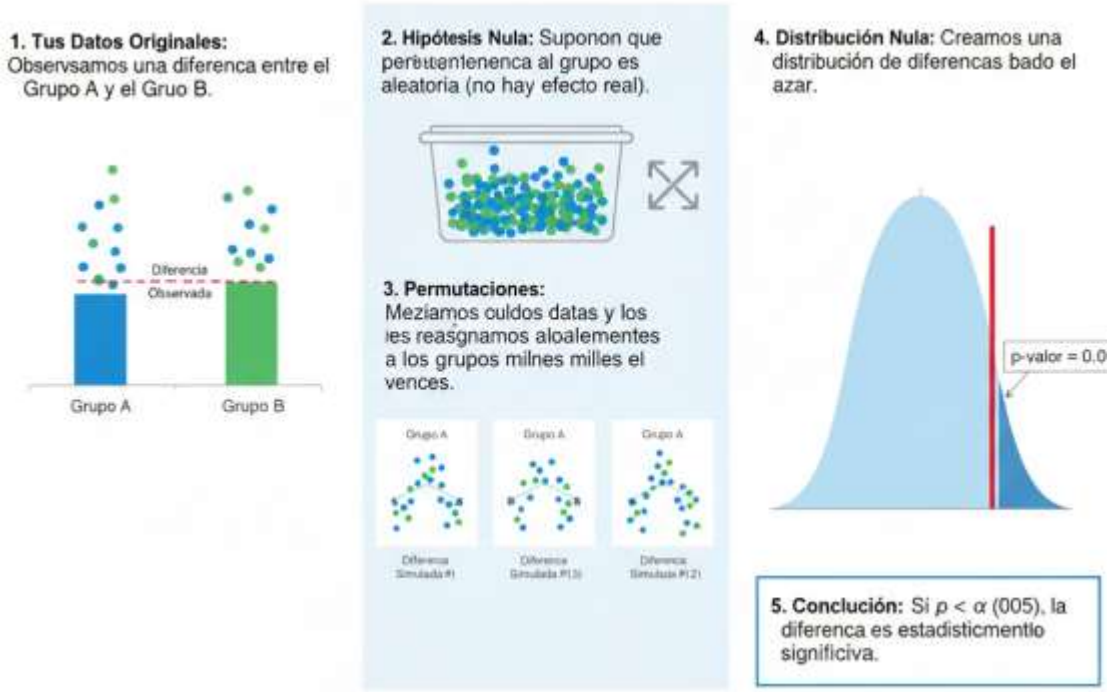


```r
grupo_A <- rnorm(20, mean = 50, sd = 10)
grupo_B <- rnorm(25, mean = 55, sd = 10)
diferencia_observada <- mean(grupo_B) - mean(grupo_A)
```

```r
datos_combinados <- c(grupo_A, grupo_B)
n_A <- length(grupo_A)
n_B <- length(grupo_B)
n_permutaciones <- 10000
```

```r
diferencias_simuladas <- numeric(n_permutaciones)
for (i in 1:n_permutaciones) {
 datos_permutados <- sample(datos_combinados)
 grupo_A_simulado <- datos_permutados[1:n_A]
 grupo_B_simulado <- datos_permutados[(n_A + 1):(n_A + n_B)]
 diferencia_simulada <- mean(grupo_B_simulado) - mean(grupo_A_simulado)
 diferencias_simuladas[i] <- diferencia_simulada
}
```

Permutation Tests

El "permutation test" (test de permutación) es un método de re-muestreo no paramétrico utilizado en estadística para determinar si las diferencias observadas entre dos o más grupos son estadísticamente significativas.

```
plot(density(diferencias_simuladas))
abline(v=diferencia_observada)
```

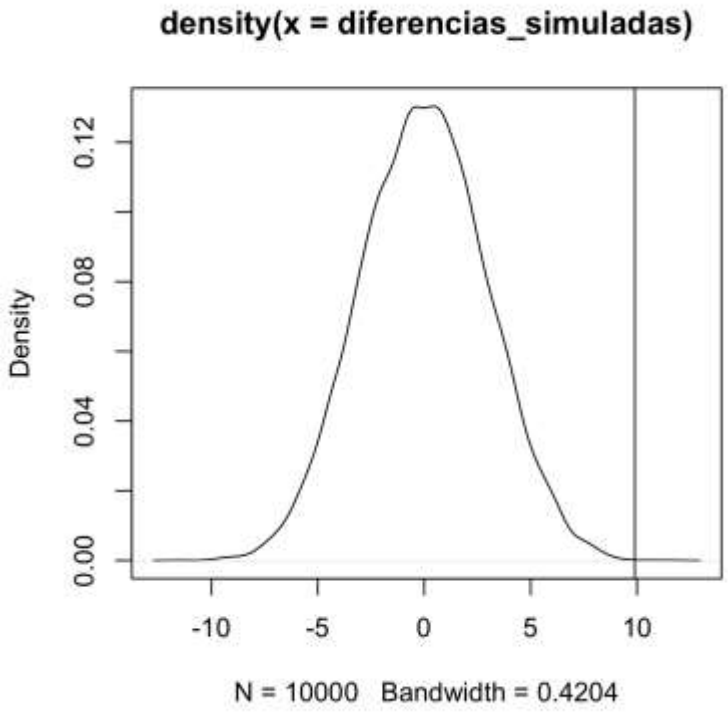


```
valor_p <- sum(abs(diferencias_simuladas) >= abs(diferencia_observada)) / n_permutaciones
```

Bootstrap

Con el permutation test inferimos la distribución del estadístico si la Ho es cierta

Con el bootstrapping queremos estimar la distribución de nuestro estadístico. También se puede utilizar para estimar p.values

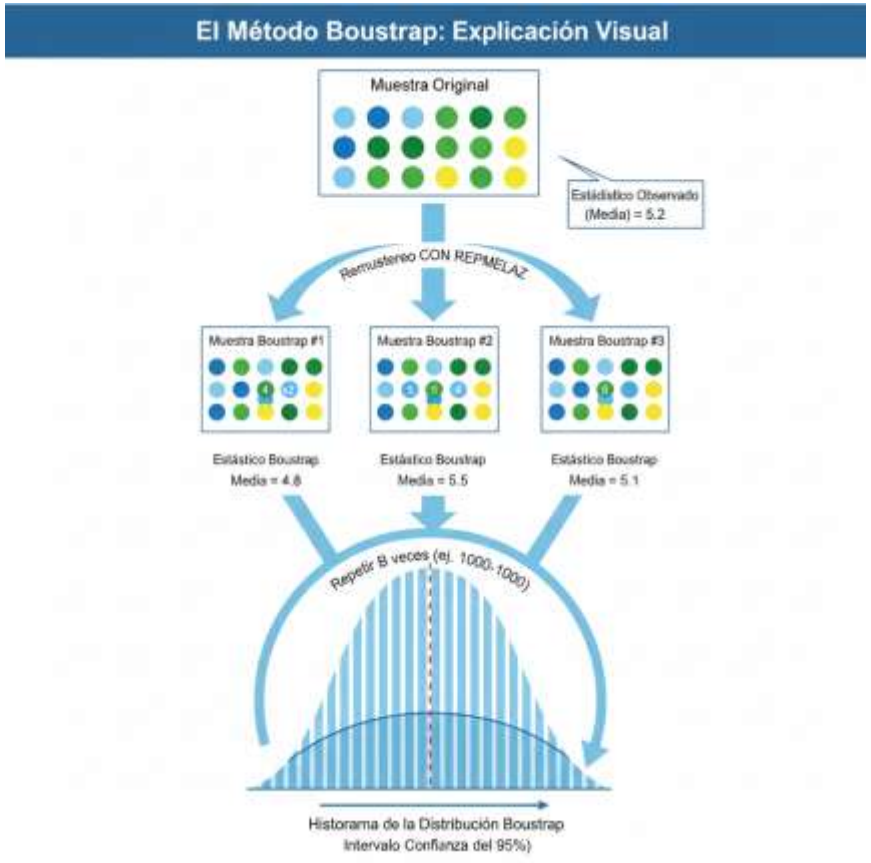


```r
x = rnorm(100,mean=5,sd=2)
medias_bootstrap = numeric(10000)

for(i in 1:10000){
  medias_bootstrap[i] = mean(sample(x,size=100,replace = TRUE))
}

hist(medias_bootstrap,50)
```

Test de bondad de ajuste

Objetivo: comprobar si F(x) es o no la función de distribución de la población.

Shapiro-Wilks: comprobar si los datos se comportan como una normal.

- Ho: los datos proceden de una normal
- H1: los datos no proceden de una normal

```
x = rnorm(100)
shapiro.test(x)

Shapiro-Wilk normality test

data: x
W = 0.98837, p-value = 0.5359

y = runif(100)
shapiro.test(y)

Shapiro-Wilk normality test

data: y
W = 0.94853, p-value = 0.0006642
```

Corrección de Hipótesis múltiple

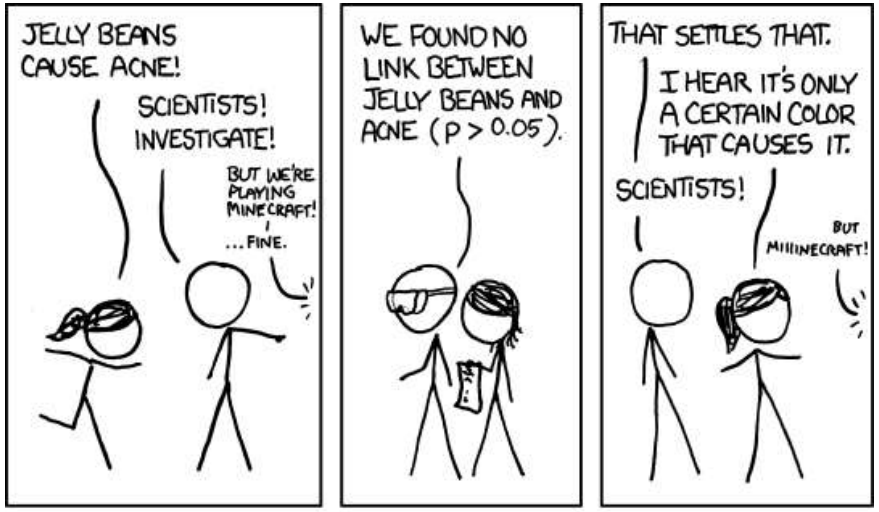

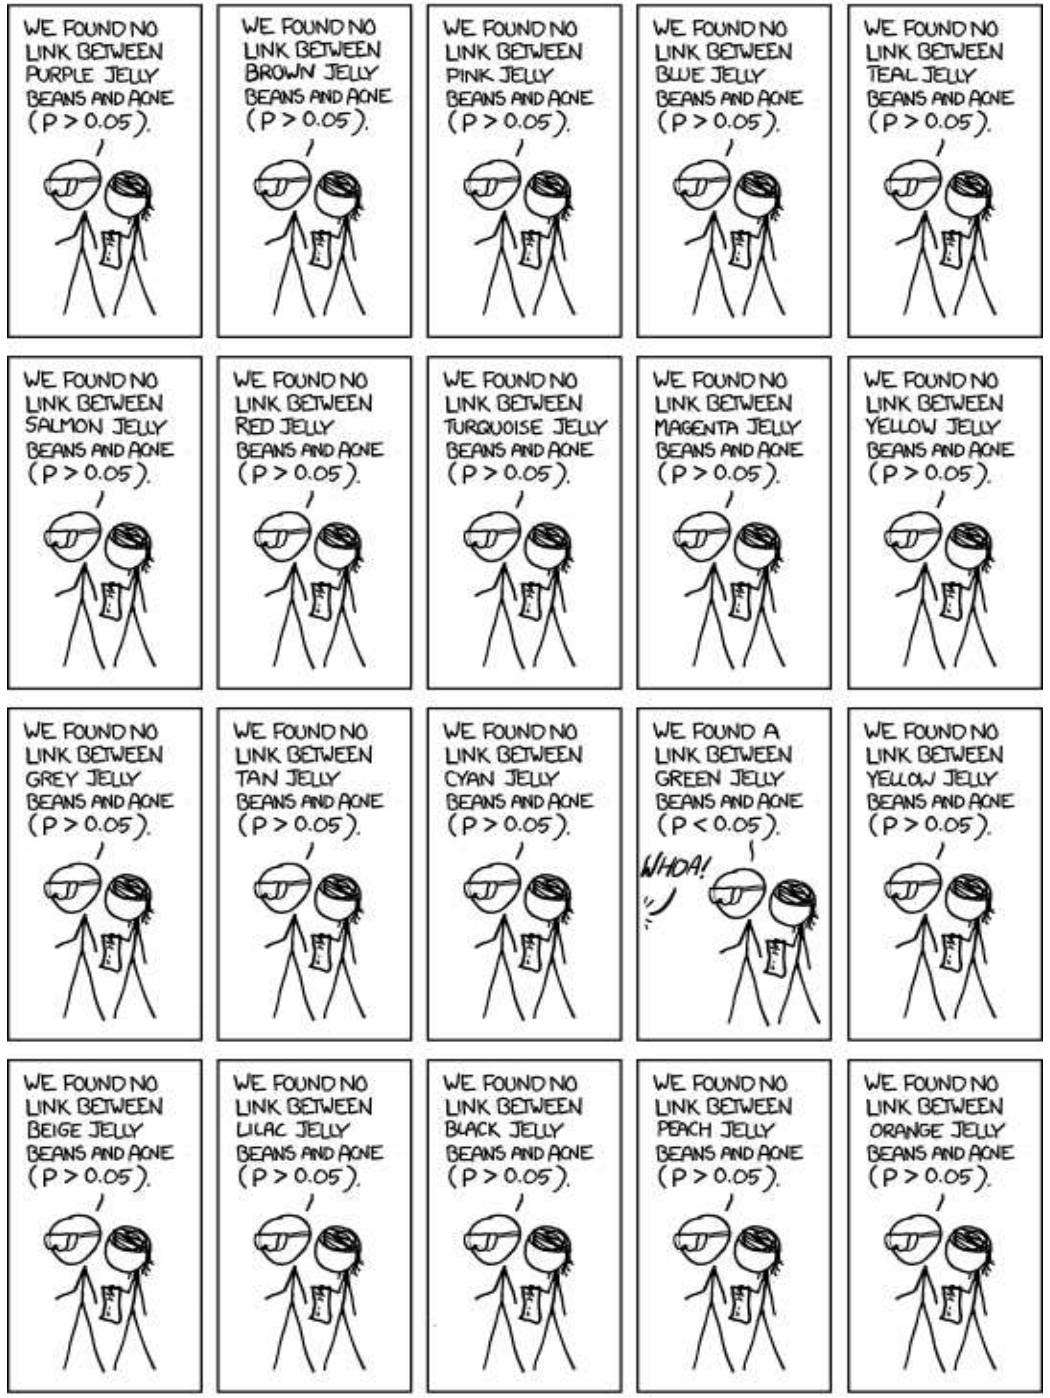

Corrección de Hipótesis múltiple

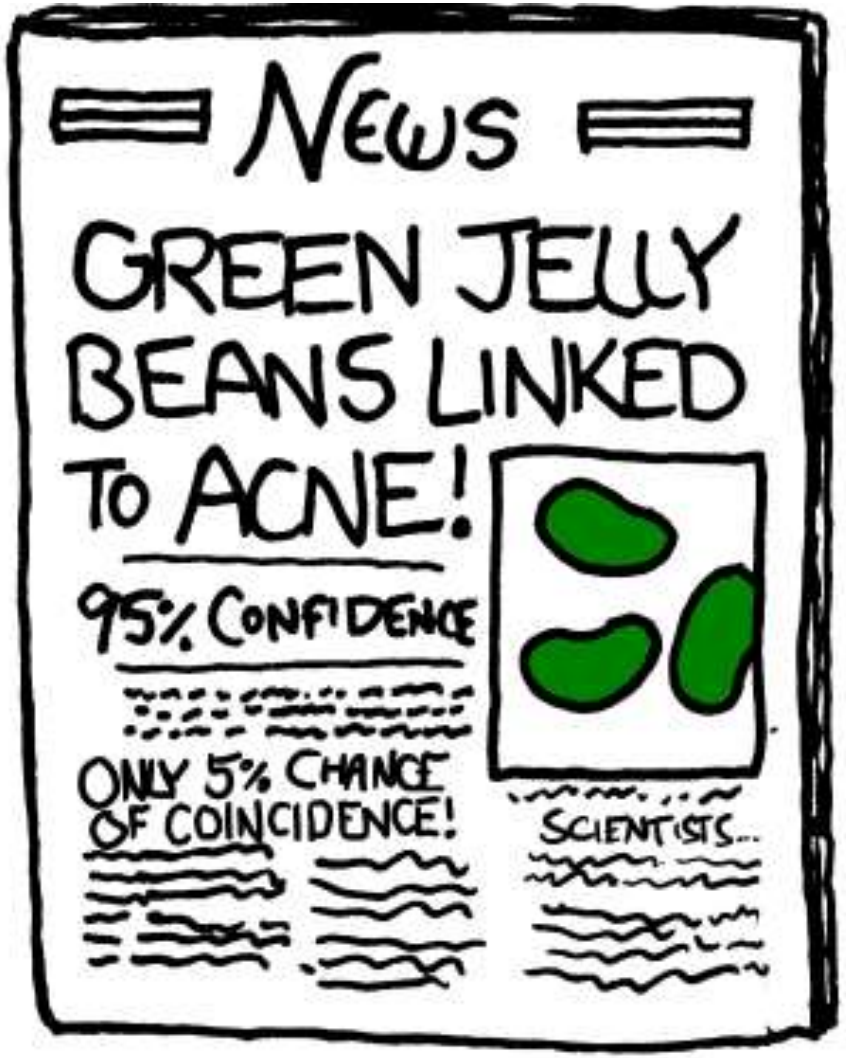

Corrección de Hipótesis múltiple

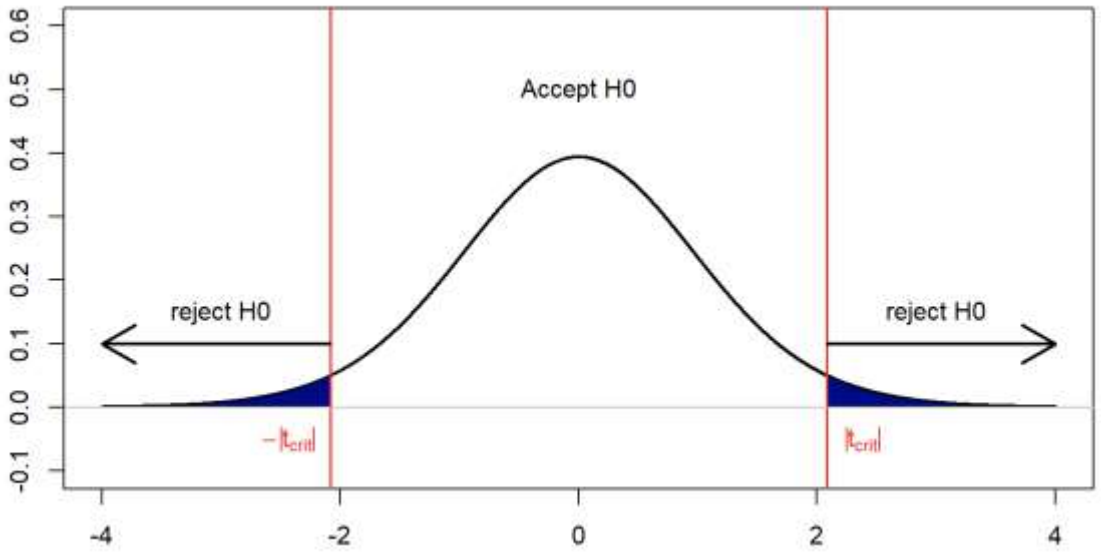

	Accept null	Reject null	Total
Null true	U	V	m_0
Alternative true	T	S	m_1
	W	R	m

Corrección de Hipótesis múltiple

```
p.values_vector = numeric(10000)
for(i in 1:10000){
  x = rnorm(20)
  y = rnorm(20)
p.values_vector[i] = t.test(x,y)$p.value
}
hist(p.values_vector,freq = F)

p.adjusted = p.adjust(p.values_vector)
```

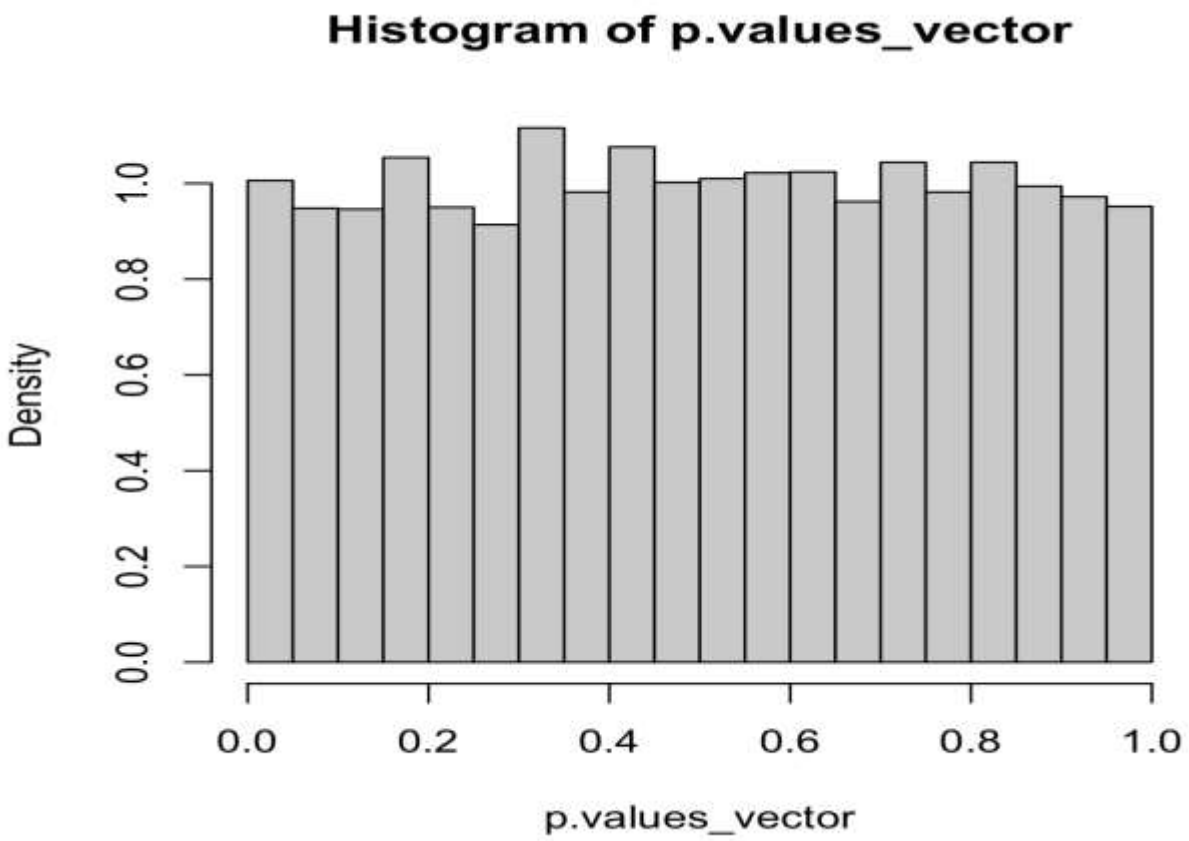

Ejercicio 1

- Read file season-1819_csv.csv
- Build two-way frequency table for the wins of Real Sociedad when playing home and away. Do the same for Barcelona. Use the column FTR: {Away(A), Home(H), Draw (D)}.
- Assess whether the wins of Real Sociedad are significantly associated with playing home. Do the same for Barcelona.

	Home	**Away**
Win	**?**	**?**
No win	**?**	**?**

Ejercicio 2

1. Read the **crimeUS. csv** file, which stores data about crime in 50 states in US.

2. Calculate the mean of African-American and Caucasian population percentages by state. Use **aggregate()** function for that purpose. Use **round()** function to remove decimal numbers.

3. Build the contingency table for District of Columbia and Hawaii states as shown on the right. Determine if there is a significant association between these states and populations. Determine the p-value.

4. Repeat Exercise 3 comparing Florida and Hawaii states.

	cauc	afam
District of Columbia	V1	V2
Hawaii	V3	V4

Ejercicio 3

1. Read the **crimeUS. csv** file, which stores data about crime in 50 states in US.

2. Transform the absolute number of violent crimes into cases per 100,000 citizens. Consider using the variables ‘violent’ and ‘population’.

3. Compare the violent crimes between Alaska, Georgia and Missouri using the ANOVA test. Are the results significant?

4. Compare now District of Columbia, Hawaii and Idaho. Draw a boxplot to visualize the differences.

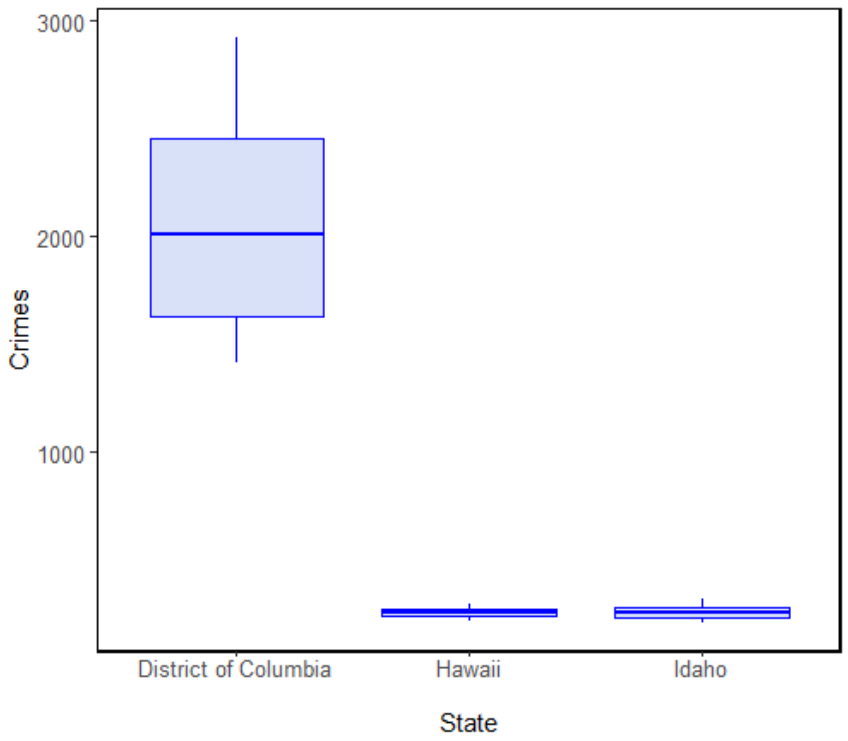

Ejercicio 4

1. Generate $\mathbf{n_1}$ random values from **N(0,1)** and $\mathbf{n_2}$ random values from **N(μ,1)**. We denote **x** the vector of obtained values. Example: $\mathbf{n_1}$=900; $\mathbf{n_2}$=100; **μ** =3

2. Determine p-value for the following test:
   $\mathbf{H_0}$: x_i follows N(0,1) ;
   $\mathbf{H_1}$: x_i follow N(μ,σ) with μ>0 (one-sided)

3. Calculate **Type I** and **Type II error** using the following criteria:

   a) **p-value** ≤ 0.05
   b) **Bonferroni** correction
   c) **Benjamini-Hochberg** correction

Functions in R:
rnorm, ***pnorm***

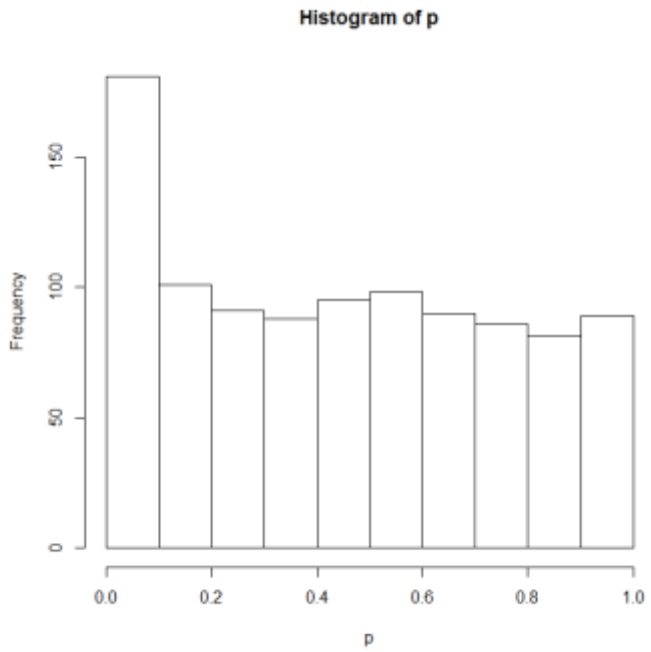

ggplot2

```
ggplot(data=cars,aes(x=speed,y=dist ))
```

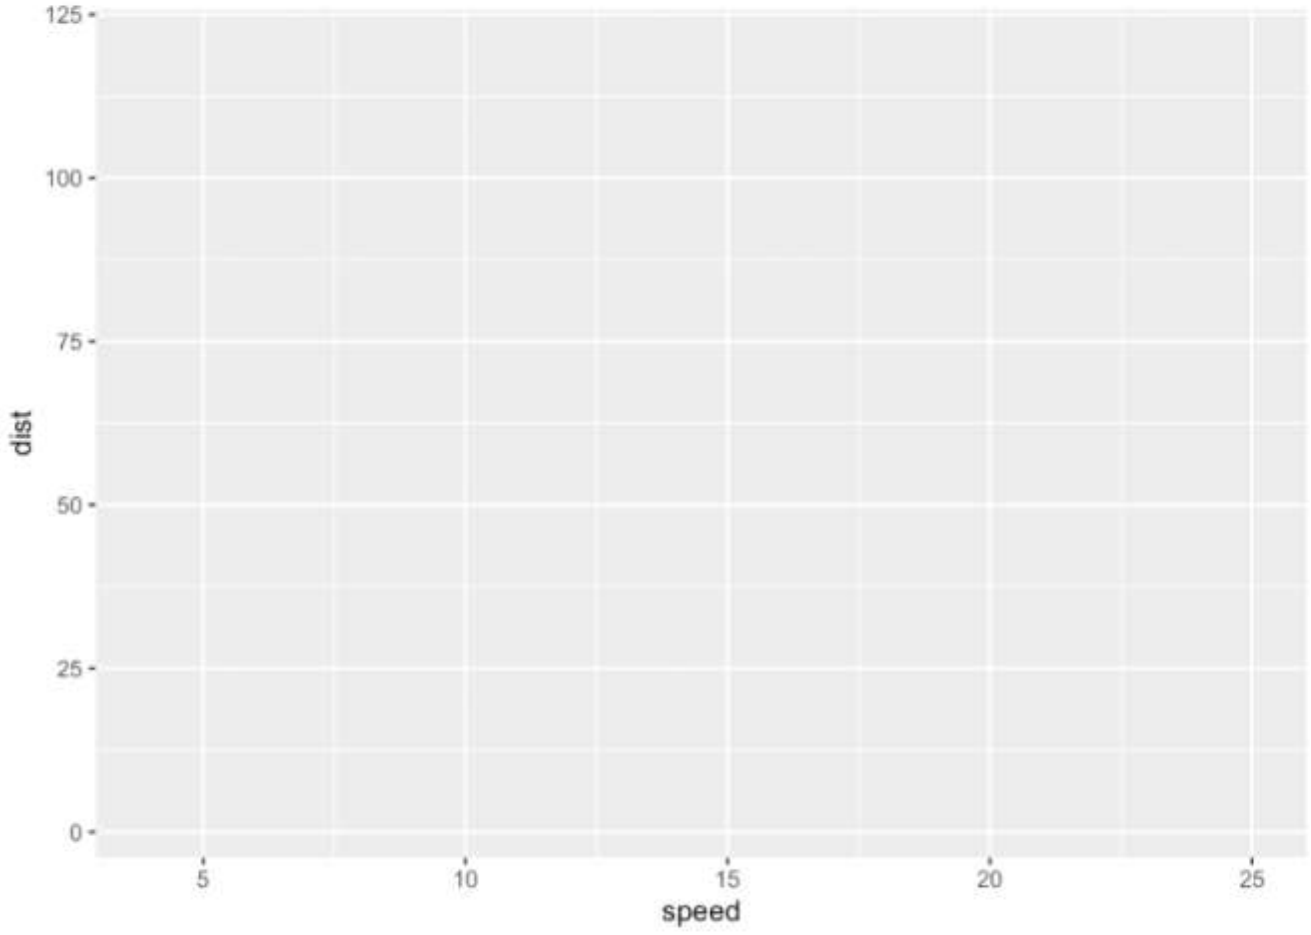

ggplot2

```
ggplot(data=cars,aes(x=speed,y=dist ))+
  geom_point()
```

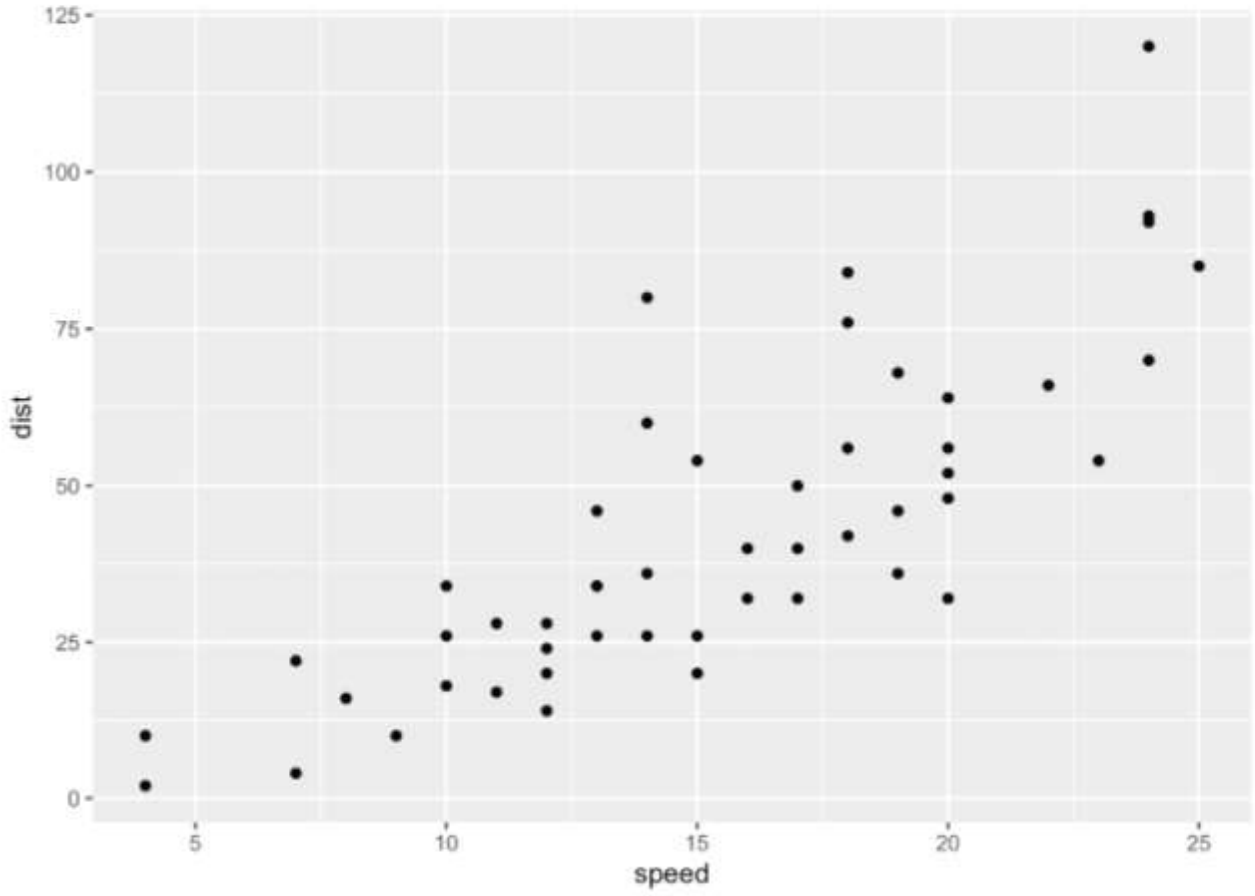

ggplot2

```
library(grid)  # para flechas con annotation_custom

ggplot(data = behobia_2021_2_senior,aes(x = time, fill = categoria)) +
  geom_density(alpha = 0.5) +
  scale_fill_manual(values = c("steelblue", "darkorange"),
                    labels = c("Senior F", "Senior M")) +  # Colores manuales y cambiamos r
  scale_x_continuous(name = "Time", breaks = seq(60, 180, by = 15), limits = c(60, 180)) +
  scale_y_continuous(name = "Density", breaks = scales::pretty_breaks(n = 8)) +
  theme_bw() +
  ggtitle("Time Density by Category") +
  theme(plot.title = element_text(hjust = 0.5, face = "bold", size = 15),
        axis.title = element_text(face = "bold.italic", size = 13),
        #axis.title.x = element_text(colour = "red"),
        axis.text = element_text(size = 10),
        legend.position = "inside",  # Oculta leyenda fuera del gráfico
        legend.position.inside = c(0.95, 0.95),  # La ubica dentro
        legend.justification = c("right", "top"),
        legend.title = element_text(face = "bold", colour = "blue", hjust = 0.5),
        legend.text = element_text(size = 10)
        ) +
  labs(x = "Time", y = "Density", fill = "Category") +
  annotate("label", x = 150, y = 0.022, label = "Un color sobre otro",
         angle = -45, fontface = "bold", size = 4,
         fill = "white", color = "black", label.size = 0.5) +  # Agrega texto dentro del gr
  annotate("segment", x = 150, xend = 105, y = 0.0205, yend = 0.008,
           arrow = arrow(length = unit(0.4, "cm")), color = "black") # Agrega flecha dentro
```

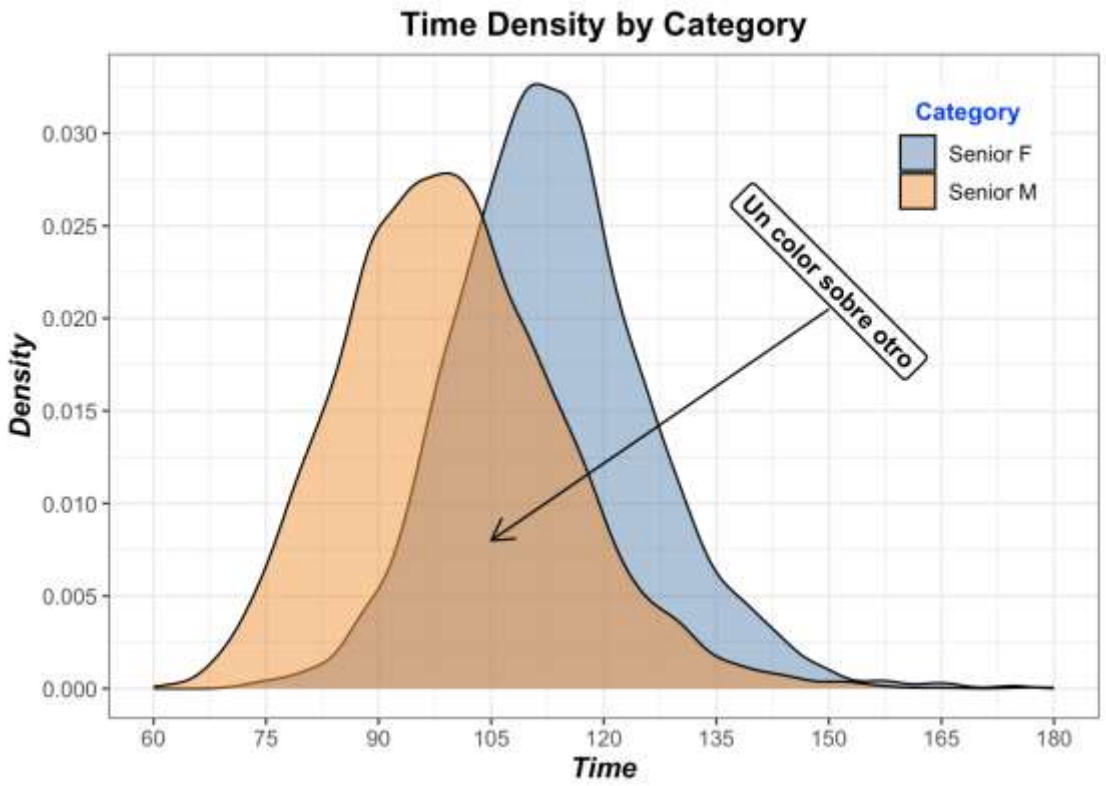

ggplot2

We will now focus on the **mpg** dataset from the **ggplot2** package. Fuel economy data from 1999 to 2008 for 38 popular models of cars.

```
> mpg
# A tibble: 234 × 11
   manufacturer      model displ  year   cyl      trans   drv   cty   hwy    fl   class
          <chr>      <chr> <dbl> <int> <int>      <chr> <chr> <int> <int> <chr>   <chr>
1          audi         a4   1.8  1999     4   auto(l5)     f    18    29     p compact
2          audi         a4   1.8  1999     4 manual(m5)     f    21    29     p compact
3          audi         a4   2.0  2008     4 manual(m6)     f    20    31     p compact
4          audi         a4   2.0  2008     4   auto(av)     f    21    30     p compact
5          audi         a4   2.8  1999     6   auto(l5)     f    16    26     p compact
6          audi         a4   2.8  1999     6 manual(m5)     f    18    26     p compact
7          audi         a4   3.1  2008     6   auto(av)     f    18    27     p compact
8          audi  a4 quattro  1.8  1999     4 manual(m5)     4    18    26     p compact
9          audi  a4 quattro  1.8  1999     4   auto(l5)     4    16    25     p compact
10         audi  a4 quattro  2.0  2008     4 manual(m6)     4    20    28     p compact
# ... with 224 more rows
```

https://r4ds.hadley.nz/data-visualize

ggplot2

```
# Example scatter plot:
Fig1 <- ggplot(data = mpg) + geom_point(aes(x = displ, y = hwy))
Fig1
Fig1+theme_bw()
```

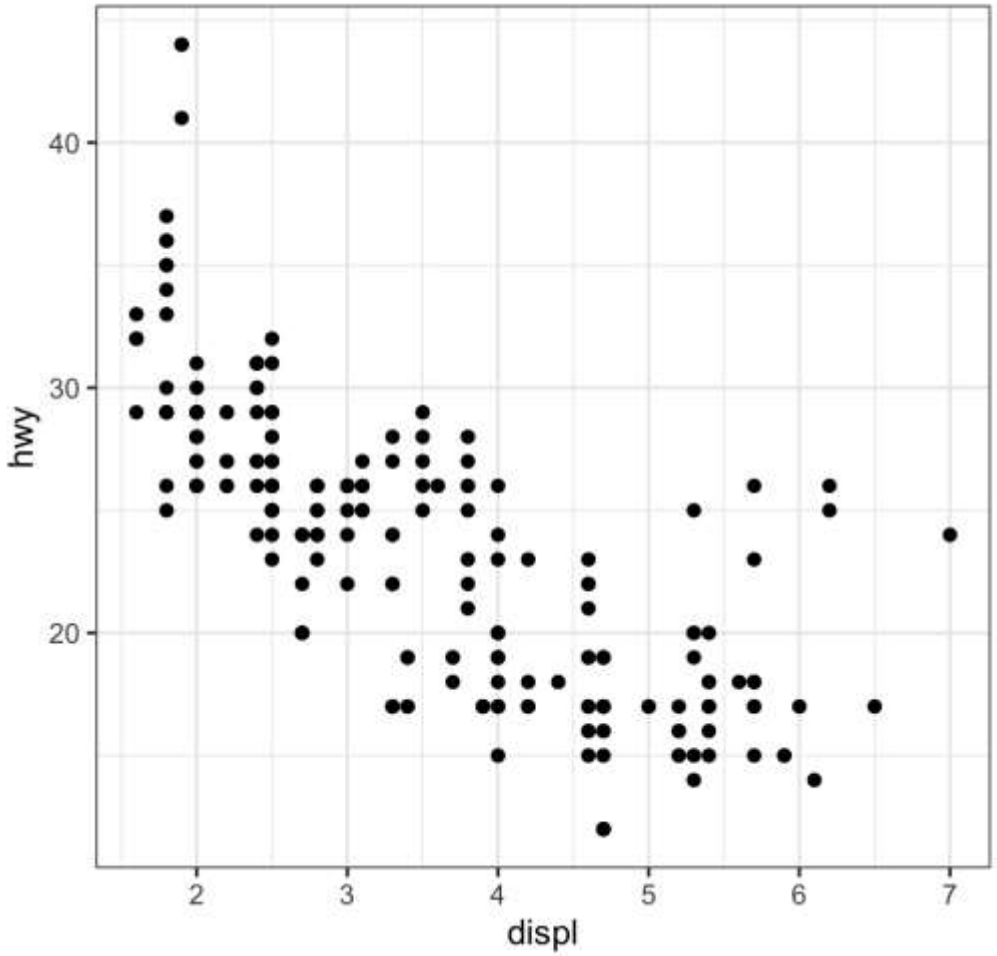

https://r4ds.hadley.nz/data-visualize

ggplot2

Vamos a ver el código para hacer la siguientes gráficas:

- scatter plot
- scatter plot con regresión lineal
- Agrupar gráficas
- boxplots
- Violin plot
- Barplot
- Heatmap

Claude

Chat GPT

Gemini

https://r4ds.hadley.nz/data-visualize

POINTS OF VIEW

Color coding

Color can add dimensionality and richness to scientific communications. In figures, color is typically used to differentiate information into classes. The challenge is picking colors that are discriminable. A systematic approach to choosing colors can help us find a lineup effective for color coding.

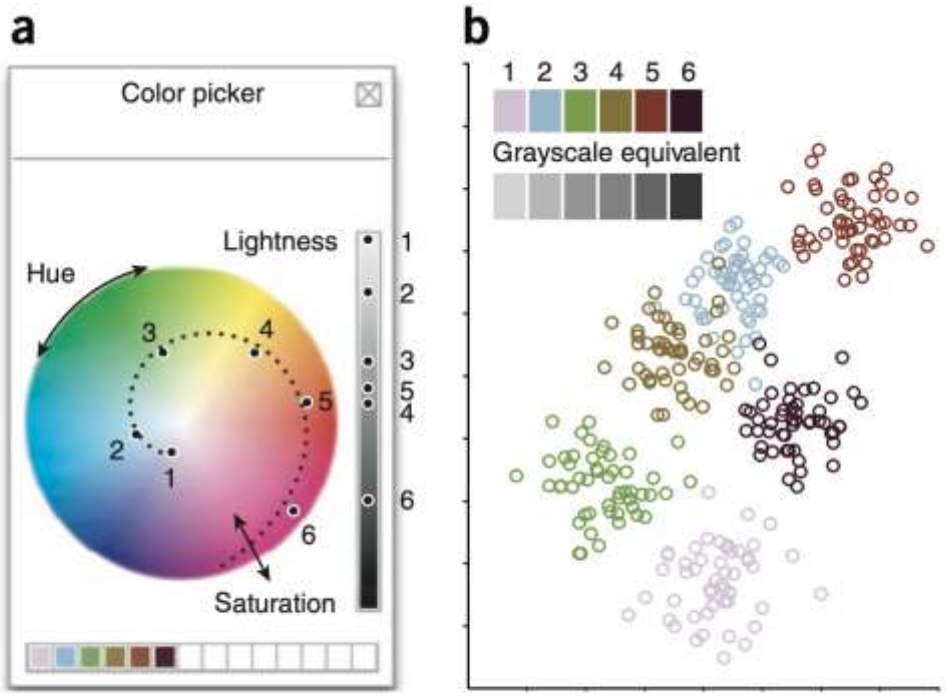

Figure 2 | Color has hue, saturation and brightness. (**a**,**b**) Colors can be tuned using a color picker (**a**). Spiraling through hue and saturation while varying lightness can generate a discernible color set distinguishable even in grayscale (points labeled 1–6).

POINTS OF VIEW

Design of data figures

Data figures or graphs are essential to life-science communication. Using these tools authors encode information that readers later decode. It is imperative that graphs are interpreted correctly. Despite the importance and widespread use of graphs, we primarily rely on our intuition, common sense and precedent in published material when creating them—a largely unscientific approach.

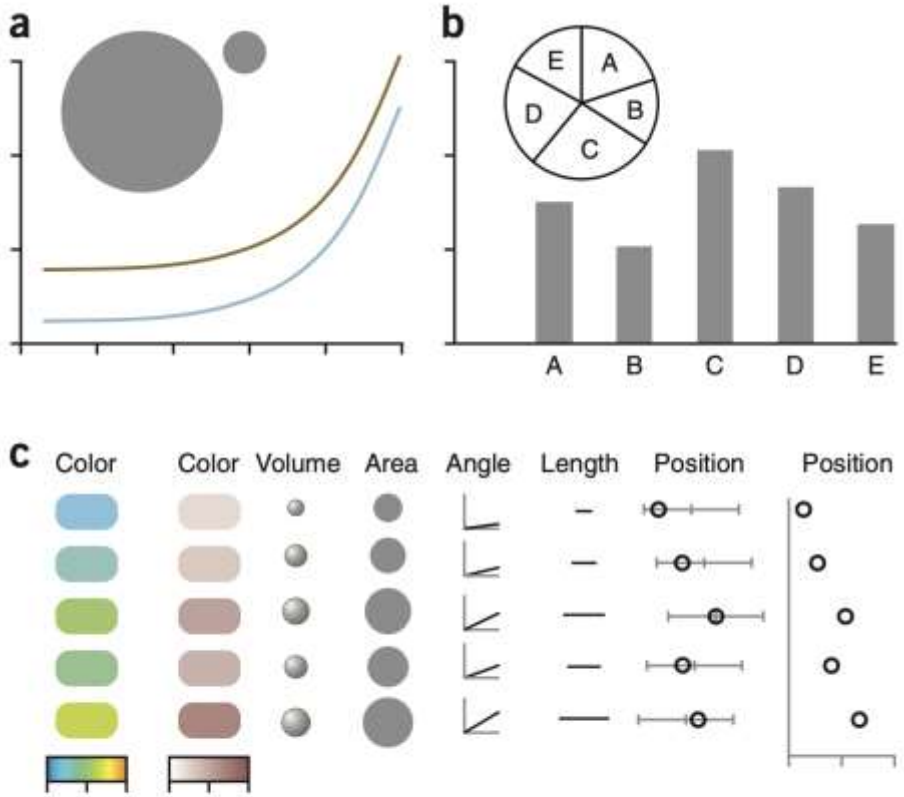

Figure 1 | Some visual estimations are more easily carried out than others. (**a**) Examples illustrating the difficulty in interpreting graphs and charts accurately. (**b**) Same data presented in a bar chart and in a pie chart. (**c**) Different visual variables encoding the same five values.

ggplot2

POINTS OF VIEW

Salience

In last month's column we explored ways to encode data that enhance 'accuracy' when readers decode information from graphs. This month, we will focus on salience as a way to differentiate graphical symbols and improve 'speed' when reading graphs.

Salience is a visual quality that sets an object apart from its surroundings. The intent is to create contrast. Incidentally, much

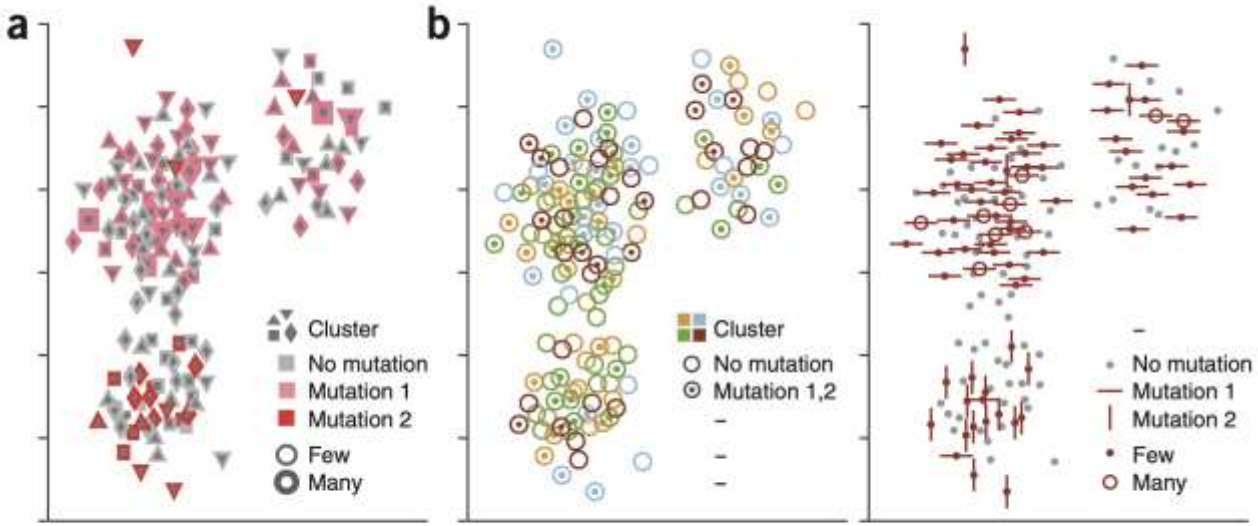

Figure 2 | Visual conjunctions. (**a**) Simultaneous use of many graphical features can impede visual assembly of the data. (**b**) Multiple views of the same data with limited parameters plotted can better communicate specific relationships.

POINTS OF VIEW

Negative space

Negative space, also known as whitespace, refers to the unmarked areas of the page. Collectively, it is the margins and the gaps between text blocks and images. Whitespace is as much a part of a composition as the titles, words and pictures. The Swiss typographer Jan Tschichold calls whitespace 'the lungs of a good design'[1]. In addition to giving elements breathing room, judicious use of whitespace can dramatically improve the visual appeal and effectiveness of figures, posters and slides.

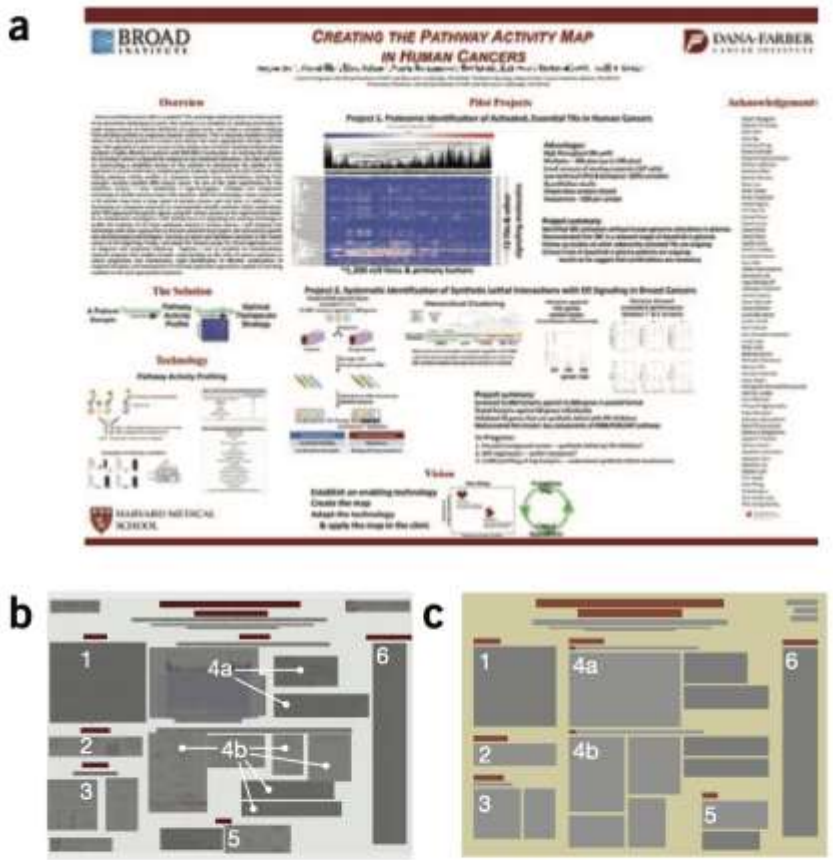

Figure 2 | Whitespace can be used to structure content. (**a**) An example of a scientific poster. (**b**) A space study reveals that contents in sections 1–6 are scattered and whitespace is fragmented. (**c**) An example of consolidated whitespace organizing contents.

POINTS OF VIEW

Color blindness

Since my first column on color coding[1] appeared, we have received a number of e-mails asking us to highlight the issue of color blindness. One of those correspondences was published in the October 2010 issue[2]. Here I offer guidelines to make graphics accessible to those with color vision deficiencies.

Color	Color name	RGB (1–255)	CMYK (%)	P	D
	Black	0, 0, 0	0, 0, 0, 100		
	Orange	230, 159, 0	0, 50, 100, 0		
	Sky blue	86, 180, 233	80, 0, 0, 0		
	Bluish green	0, 158, 115	97, 0, 75, 0		
	Yellow	240, 228, 66	10, 5, 90, 0		
	Blue	0, 114, 178	100, 50, 0, 0		
	Vermillion	213, 94, 0	0, 80, 100, 0		
	Reddish purple	204, 121, 167	10, 70, 0, 0		

Figure 2 | Colors optimized for color-blind individuals. P and D indicate simulated colors as seen by individuals with protanopia and deuteranopia, respectively.

Data Science

Introduction to Hypothesis Testing

Dr. Juan A. Ferrer-Bonsoms jafhernandez@unav.es

Tecnun Universidad de Navarra | ESCUELA DE INGENIERÍA INGENIARITZA ESKOLA SCHOOL OF ENGINEERING